



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.


다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

멀티모달 데이터 기반
대규모 언어 모델(LLM)을 이용한
주가 변동 예측
- 한국 주식 시장을 중심으로 -

연세대학교 공학대학원
산업정보경영
원 재 희

멀티모달 데이터 기반
대규모 언어 모델(LLM)을 이용한
주가 변동 예측

- 한국 주식 시장을 중심으로 -

지도교수 윤 현 수

이 논문을 석사 학위논문으로 제출함

2024년 6월 17일

연세대학교 공학대학원

산업정보경영

원 재 회

원재회의 석사 학위논문을 인준함

심사위원 윤 현 수 인

심사위원 오 재 주 인

심사위원 김 영 상 인

연세대학교 대학원

2024년 6월

목 차

그림 차례	iii
표 차례	iv
국문 요약	v
 제1장 서론	 1
1.1 연구 배경	1
1.2 연구 목적	6
1.3 논문의 구성	8
제2장 이론적 배경	9
2.1 주가 예측을 위한 전통적인 접근법	9
2.2 LLM을 활용한 최근 연구 동향	13
2.3 언어모델에서의 프롬프트 기법 연구 동향	16
2.3.1 Multimodal Chain of Thought	16
2.3.2 Self Evaluation	18
2.3.3 Self Consistency	20
제3장 연구 방법	22
3.1 사용 모델	22
3.2 연구 대상	23
3.3 데이터 수집 및 전처리	25
3.3.1 사업보고서 내 ‘사업의 개요’	27
3.3.2 최근 기업 뉴스	27
3.3.3 최근 경제 뉴스	28

3.3.4 재무제표 주요 지표	31
3.3.5 주가 데이터	31
3.3.6 차트 지표	32
3.3.7 주별 주가 변동률	32
3.3.8 주가 차트 이미지	33
3.4 평가 방법	35
3.4.1 Direction Accuracy	35
3.4.2 Bin Score	35
제4장 실험 및 결과	37
4.1 실험 설계	37
4.2 실험 결과	42
4.2.1 섹터 및 기업별 Direction Accuracy	42
4.2.2 시가총액 기준별 Direction Accuracy	44
4.2.3 섹터 및 기업별 Bin Score	46
4.2.4 시가총액 기준별 Bin Score	48
제5장 결론	51
5.1 연구 결과 및 시사점	51
5.2 한계 및 발전 방향	57
참고 문헌	59
영문 요약	65

그림 차례

그림 1-1. 연구의 개요	2
그림 2-1. 멀티모달 CoT 프레임워크 개요 - Zhang et al. (2023)	16
그림 2-2. Self Evaluation 3가지 방식 - Ren et al. (2023)	18
그림 2-3. Self Consistency 3단계 절차 - Wang et al. (2023)	20
그림 3-1. 주가 변동 예측 위한 하위 질문 생성	25
그림 3-2. LLM을 활용한 최근 기업 뉴스 요약 프로세스	29
그림 3-3. Gensim을 활용한 최근 경제 뉴스 요약 프로세스	30
그림 3-4. 추출한 주가 차트 이미지	34
그림 4-1. 이미지, 텍스트, Tabular 데이터 기반 LLM을 이용한 예측	39
그림 4-2. Self-Evaluation, Zero-shot CoT, 최종 예측	40
그림 4-3. 멀티모달 데이터 기반 주가 변동 예측 실험 개요	41

표 차 례

표 3-1. 분석 대상 기업 목록	23
표 4-1. 실험 결과 - 섹터 및 기업별 Direction Accuracy	42
표 4-2. 실험 결과 - 시가총액 기준별 Direction Accuracy	44
표 4-3. 실험 결과 - 섹터 및 기업별 Bin Score	46
표 4-4. 실험 결과 - 시가총액 기준별 Bin Score	48

국 문 요 약

멀티모달 데이터 기반 대규모 언어 모델(LLM)을 이용한 주가 변동 예측 - 한국 주식 시장을 중심으로 -

본 연구는 대규모 언어 모델(Large Language Models, LLM), 특히 GPT를 활용하여 멀티모달 데이터를 기반으로 한국 주식 시장 주가 변동의 설명 가능한 예측을 실험적으로 탐구한다. 이를 통해 기존 예측 방법론과는 차별화된 새로운 예측 접근법을 제안한다. 선행 연구에서는 예측을 위한 입력 데이터가 주로 텍스트, 이미지, 또는 표(Tabular)와 같은 단일 형태에 집중되어 있었으나 본 연구는 다양한 형태와 시간 범위의 데이터를 통합하여 예측함으로써 복잡한 환경에서도 보다 유연한 분석이 가능함을 보여준다. 이를 통해, 금융 시장 분석 및 투자 결정 과정에서 LLM의 적용 범위 및 가능성을 확장하고자 한다.

GPT의 최신 모델인 GPT-4o를 사용하여 기업별, 섹터별, 시가총액 기준 등 다양한 관점에서 주가 변동 예측 정확도를 비교하고 효과성을 평가한다. 2024년 1월부터 5월까지 월말 영업일인 2024년 1월 31일, 2024년 2월 29일, 2024년 3월 29일, 2024년 4월 30일, 2024년 5월 31일을 예측일로 선택하였다. 주가 변

동 예측은 멀티모달 CoT 프레임워크에 프롬프트 기법으로 Least-to-Most, Self Evaluation과 Zero-shot CoT 등을 적용하였으며 멀티모달 데이터 환경에서의 효과적인 프롬프트 구성 방법을 모색하고자 하였다.

실험 결과, 정보기술(삼성전자, 롯데에너지머티리얼즈)과 헬스케어(셀트리온, 한올바이오파마), 필수소비재(한국전력, 삼양식품) 섹터는 예측 방향 정확도와 예측 근접도 방면에서 모두 높은 정확도를 보였고, 시가총액이 큰 기업일수록 대체적으로 예측 성능이 뛰어났다. 반면, 금융(기업은행, JB금융지주), 산업재(대한항공, 두산퓨얼셀), 통신서비스(KT) 섹터와 시가총액이 상대적으로 낮은 기업일수록 예측 성능이 낮았다. 이는 기업 규모와 섹터별로 예측 정확도에 차이가 있음을 보여주며, 향후 기업 규모 및 섹터에 특화된 데이터를 추가로 수집하고 적합한 프롬프트를 설계하여 최적화할 필요가 있다.


본 연구는 다양한 유형의 데이터를 효과적으로 처리하고 결합하여 주가 변동을 예측하는 새로운 방법론을 제시하며, 이는 금융 시장의 복잡한 동향을 이해하고 예측하는데 기여할 수 있다. GPT와 같이 범용적인 데이터로 학습된 모델을 활용하여 전문적인 데이터 분석 및 설명 가능한 예측이 가능함을 확인하였으며 고급 머신러닝이나 딥러닝 기술을 구체적으로 구현하지 않아도, 적절한 프롬프트 설계를 통해 누구나 복잡한 분석을 유연하게 수행할 수 있음을 보여준다. 향후 금융뿐만 아니라 다양한 분야에서 멀티모달 기반 LLM을 활용한 데이터 분석 및 예측의 활용을 더욱 확대할 필요가 있음을 시사한다.

핵심되는 말 : 멀티모달, LLM, GPT, 프롬프트 엔지니어링, 주가 변동 예측, KOSPI

제 1 장 서 론

1.1. 연구 배경

인공지능 분야에서 대규모 언어 모델(Large Language Models, LLMs)은 자연어 처리의 혁신을 주도하고 있다. 복잡한 언어 이해 및 생성 능력을 바탕으로 다양한 분야에서 새로운 가능성을 열어가고 있으며, 특히 2023 년 3 월을 기준으로 GPT-4 와 같은 최신 모델들은 텍스트 데이터를 넘어 이미지, 오디오와 같은 멀티모달 데이터를 통합적으로 처리하는 능력도 갖추게 되었다. 이는 기존의 데이터 분석에서 단일 도메인 데이터 처리 방식을 넘어, 여러 유형의 데이터를 결합하여 보다 깊이 있는 분석을 가능하게 한다. 기술의 발전에 따라 다양한 시도를 해왔던 주가예측 분야에서도 LLM 을 활용한 연구가 활발히 진행되고 있다. 하지만 Lopez-Lira et al. (2023)의 연구를 비롯하여 최근 대규모 언어 모델을 활용한 주가 예측 연구들은 주로 텍스트 데이터 활용에 초점을 맞추고 있다. 이러한 방식은 금융 시장의 다양한 정보를 포괄적으로 활용하는 데 한계가 있다. 예를 들어, 뉴스 기사나 재무



[그림 1-1. 연구의 개요]

보고서만을 활용하는 접근은 시각적 데이터에서 나타나는 패턴이나 동향을 간과할 수 있다.

Zhang et al. (2023)의 연구에 따르면, 멀티모달 데이터를 입력으로 처리할 때, 텍스트 데이터에서 얻을 수 있는 정보와 이미지 데이터에서 관찰할 수 있는 직관적인 패턴을 결합하여 분석함으로써 모델의 성능을 향상시킬 수 있다. 이를 바탕으로 본 연구는 기업 및 경제 뉴스, 사업보고서와 같은

텍스트 데이터와 주가 차트 이미지와 같은 시각적 데이터를 통합하여 LLM에 입력함으로써 멀티모달 데이터 기반의 예측을 수행하고 LLM 기반 주가 변동 예측의 새로운 가능성을 모색하고자 한다. 최근 활발히 진행되고 있는 연구를 확장하는 차원에서, 다양한 데이터 유형을 결합, 활용하여 상호 보완적인 장점을 극대화하고자 하였다.

LLM을 사용하는 경우, 시간적 범위와 형태가 다른 다양한 데이터 소스를 통합하여 분석할 수 있다. 구체적으로, 최근 2주 동안의 뉴스 기사, 지난 1년 동안의 주가 차트 이미지, 최근 분기의 재무제표 등 다양한 시간과 기간에 걸친 데이터를 하나의 모델에 입력으로 통합하는 것은 기존의 딥러닝이나 머신러닝 모델에서는 처리하기 어려웠던 새로운 분석 가능성을 제시한다. 딥러닝과 머신러닝을 활용한 데이터 분석에서는 입력 데이터의 시간적 범위와 형태를 일치시키는 것이 필수적이다. 즉 데이터를 분석에 사용하기 위해서는 모든 입력 데이터가 동일한 시간대에 맞춰져 있어야 하고 이미지 혹은 텍스트 등의 동일한 데이터 형식을 따라야 한다. 그러나 LLM 기술의 발전으로, 이제는 시간 범위 일치나 데이터 형식의 동질성이 충족되지 않아도 데이터 분석이 가능하다. LLM은 다양한 형태와 시간대의 데이터를 자연스럽게 이해하고 통합할 수 있는 능력을 갖추고 있어, 데이터의 다양성과 복잡성이 증가해도 정밀하고 깊이 있는 분석이 가능하고 데이터를 보다 효율적으로 처리하고 분석할 수 있다.

예측과 같은 복잡한 문제 해결에 있어 단순히 다양한 데이터를 제공하는 것만으로는 충분하지 않다. LLM 은 고도화된 인공지능으로서 제공된 프롬프트의 구조와 내용을 기반으로 응답을 생성한다. (Qiao et al. (2022)) 따라서 동일한 데이터를 제공하더라도 프롬프트의 질문 방식에 따라 얻을 수 있는 답변의 내용과 품질이 크게 달라질 수 있다. (Rajagopal et al. (2021)) 주가 예측과 같은 민감하고 복잡한 주제를 다룰 때, LLM 은 직접적인 예측을 제공하기보다는 제공된 데이터와 질문의 형식에 따라 분석 결과를 제시하는 접근 방식을 취한다. 이러한 접근은 프롬프트의 구조와 내용이 결과에 큰 영향을 미칠 수 있음을 보여준다. 따라서 프롬프트 엔지니어링이 중요하며, 잘 설계된 질문을 통해서만 LLM 에서 원하는 유형의 분석 정보를 효과적으로 추출할 수 있다. 본 연구는 프롬프트의 구성이 얼마나 결정적인 역할을 할 수 있는지 강조하며 원하는 답변을 얻기 위한 전략적인 질문 설정의 중요성을 부각한다. 또한, 프롬프트 엔지니어링 기법을 통합하여 LLM 의 분석 능력을 극대화하는 방법을 탐색한다.

다양한 분야에서 LLM 의 활용도가 증가하는 가운데, 금융 시장에서는 복잡한 데이터를 분석하고 예측하는 데 LLM 의 잠재력이 두드러지고 있다. 이러한 동향은 본 연구가 금융 시장 분석 및 투자 결정 과정에서 인공지능 기술의 적용 범위와 가능성을 확장할 수 있는 중요한 기반을 마련한다는 점에서 그 중요성을 더한다. 본 연구는 멀티모달 데이터 분석을 중심으로,

데이터 다양성과 복잡성에 대한 기존 주가 변동 예측 방법론의 한계를 극복하고 최적의 프롬프트 설계를 통해 설명 가능한 주가 변동 예측 가능성을 제시한다. 이 과정에서 프롬프트 엔지니어링은 단순한 기술적 접근을 넘어서, 데이터 분석 시 인간의 직관과 전문 지식을 AI 와 어떻게 통합할 수 있는지에 대한 깊은 이해를 필요로 한다. 본 연구는 GPT-4o 모델을 활용한 주가 변동 예측 과정에서 프롬프트 엔지니어링을 통해 분석과 예측의 범위를 확장함으로써 금융 분야에서의 인공지능 응용 연구에 기여하고자 한다.

1.2. 연구 목적

본 연구는 두 가지 목표를 가진다. 첫째, 한국 주식 시장을 중심으로 대규모 언어 모델(Large Language Models, LLM)을 활용한 멀티모달 데이터 분석을 통해 주가 변동 예측 가능성을 실험적으로 탐구하는 것이다. 둘째, 기업 규모, 섹터 등의 다양한 관점에서 주가 변동 예측 정확도를 비교하고 그 효과성을 평가하는 것이다.

이와 같은 목표를 달성하기 위해, GPT-4o 모델을 활용하여 주가 변동 예측의 새로운 멀티모달 접근법을 제시하는 것이 연구의 목적이다. Tabular 데이터나 텍스트 데이터 중심의 단일 모달 분석을 넘어 이미지, 텍스트, 각종 Tabular 데이터와 결합하여 멀티모달로 보다 다차원적인 분석을 수행한다는 점에서 본 연구는 기존 선행연구와 차별화된다.

분석을 수행하는 과정에서 다양한 프롬프트 기법을 적용해봄으로써 예측 결과 변화를 관찰하고 효과적인 구성을 모색한다. 프롬프트 엔지니어링은 LLM 을 활용한 분석에서 중요한 역할을 하며, Rajagopal et al. (2021)의 연구결과와 같이 주어진 질문의 형태와 내용에 따라 모델의 응답 품질과 유용성이 크게 달라질 수 있으므로 멀티모달 데이터를 예측에 효율적으로 활용하기 위한 프롬프트 구성 방법을 탐색하고 제안한다.

연구 목적을 바탕으로, 본 연구는 다음 두 가지 주요 기여점을 가진다.

1. 멀티모달 데이터 분석의 혁신: GPT-4o 모델을 활용하여 이미지와 텍스트 데이터를 결합하는 새로운 주가 변동 예측 방법을 제안함으로써, 다양한 데이터 형태를 통합하여 보다 정밀하고 설명 가능한 예측을 제공한다. 금융 분야의 의사결정을 더욱 풍부한 정보에 기반하여 진행할 수 있도록 돕는다.
2. 프롬프트 엔지니어링과 LLM 응용 확장: LLM을 활용한 프롬프트 방법론을 실험적으로 검증하고 다양한 프롬프트 구성의 효과를 확인하며 프롬프트 엔지니어링의 중요성을 강조한다. 이 방법론은 금융 시장 예측 뿐만 아니라 여러 산업에서 LLM 기반 데이터 분석 및 예측 발전에 기여할 수 있다.

본 연구는 LLM을 활용하여 실질적인 문제 해결에 적용해봄으로써 그 적용 잠재력을 보여준다. 또한, 후속 연구에서 다양한 산업군에 참고자료로 활용될 수 있을 것으로 기대된다.

1.3. 논문의 구성

본 논문의 구성은 다음과 같다.

제 2 장에서는 이론적 배경을 통해 주가 변동 예측을 위한 전통적 통계적 기법, 머신러닝 및 딥러닝 기반의 접근법을 살펴보고, LLM 을 활용하여 시도되고 있는 최근 주가 예측 연구 동향에 대해 설명하며, 본 연구에서 다루게 되는 주요 프롬프트 기법에 대해 소개한다. 제 3 장에서는 본 연구에서 사용한 모델과 예측 대상, 실험에 사용한 데이터와 전처리 과정, 그리고 모델의 성능을 평가하는 방법에 대해 논한다. 이후 제 4 장에서 실험의 구조를 설명하고 결과를 분석하였으며 마지막 제 5 장에서는 제 4 장의 연구 결과에 대한 해석과 결론, 연구의 한계점, 이에 대한 향후 개선 방향에 대하여 논한다.

제 2 장 이론적 배경

2.1. 주가 예측을 위한 전통적인 접근법

주가 예측은 재무, 경제학 분야에서 오랫동안 중요한 연구 주제로 자리잡고 있다. 특히 머신러닝 및 딥러닝 기술의 적용을 통해 다양한 알고리즘을 활용한 주가 예측 방법론이 연구되었는데, 본 장에서는 주가 예측에 있어 이러한 기술들의 적용 사례를 고찰하고, 사용된 알고리즘, 데이터 유형, 평가 방법 및 연구들의 한계에 대해 논의한다.

주가 예측을 위해 연구에서 널리 사용되는 알고리즘은 통계적 기법으로 Ariyo et al. (2014) 연구에서의 ARIMA(자기 회귀 누적 이동 평균), ARMA-GARCH 와 같은 전통적인 시계열 모델이 있고, 머신러닝 기법으로 Khaidem et al. (2016) 연구의 Random Forest, Hu et al. (2013) 연구의 SVM(Support Vector Machine) 등이 있으며 이로써 주가 방향성 예측에 활용할 수 있다. 딥러닝 기법의 경우 순환 신경망이 시계열 데이터의 복잡한 패턴을 학습하는데 효과적으로 사용되므로 Mehtab et al. (2020) 연구의 LSTM(Long Short-Term Memory), Chen et al. (2023) 연구의 GRU(Gated Recurrent Units) 등이 있으며 Li et al. (2022) 연구에 따르면

CNN(Convolutional Neural Network)과 같은 모델도 구조화된 시계열 데이터인 주가 예측에 사용되기도 한다.

예측에 사용되는 데이터 유형은 Tabular, 텍스트, 이미지 데이터가 있다. Tabular 데이터는 류형선 외(2013) 연구와 같이 주로 주식의 역사적 가격 데이터(시가, 종가, 최고가, 최저가 등)와 거래량, 금리 등 시계열 데이터로 구성되며, 이는 기본적인 예측 모델의 입력 변수로 활용된다. 텍스트 데이터로는 뉴스 헤드라인, 뉴스 내용, SNS 게시물, 재무 보고서 등에서 추출되며, 주로 자연어 처리 기술을 통해 시장의 감성 및 트렌드를 분석하는데 사용된다. 구체적으로 Xu et al. (2018)의 연구진은 소셜 미디어 플랫폼 Twitter에서 수집한 데이터와 주가 정보를 결합하여 'StockNet'이라 명명된 새로운 모델을 개발해 주가 예측에 활용했고 Hájek et al. (2013)의 연구진은 신경망과 ϵ -서포트 벡터 회귀를 사용하여 연간 보고서의 감정 정보가 주식 가격에 중요한 영향을 미친다는 것을 보였다. Kalyani et al. (2016)는 금융 뉴스 기사를 분석하여 그 기사의 긍정적 또는 부정적 내용을 파악하고, 감정 분석 결과 기반으로 주가를 예측하였으며 이 과정에서 Random Forest와 SVM 두 가지 모델이 좋은 성능을 보여 전체적으로 모델의 정확도가 기존 무작위 뉴스 분류 후 예측 대비 80% 이상 달성을 보여줬다. 마지막으로 Lee et al. (2019)는 주가 차트 이미지와 주가를 입력 데이터로 사용하여 CNN과 Deep Q-Network를 활용하여 주가 예측을 실시, 그 결과 단일 국가의 주식

차트 패턴에서 학습된 모델이 미국을 포함한 여러 국가의 주식 시장에서도 효과적으로 수익을 낼 수 있음을 보여준다.

주가 예측 모델의 성능은 정확도, 수익률을 통해 평가된다. (Kalyani et al. (2016)) 이 중 정확도는 모델이 예측한 주가의 방향(상승 또는 하락)이 실제와 얼마나 일치하는지를 나타내며, 실제 거래에서의 수익률은 가능한 시나리오를 바탕으로 시뮬레이션을 통해 성능을 평가함에 따라 모델의 경제적 유용성을 평가하는 데 중요한 지표로 활용된다. (Lee et al. (2019))

하지만 이러한 기존 대부분의 연구들은 과거 데이터에 기반하여 모델을 학습시키고 평가하는데, 이로 인해 과적합 위험이 있다. 금융 시장의 높은 변동과 불확실성은 모델 예측의 정확도를 제한하는 주요 요인으로 작용하여 성능 저하로 이어진다. 박선영 외(2024), 신동하 외(2017), 주성준 외(2023) 연구에 따르면, 특히 LSTM 모델은 주로 최근 데이터의 패턴을 반영하여 결과를 예측하며, 이는 모델이 주가의 이전 움직임을 단순히 따라가는 경향을 보인다는 것을 의미한다. 주가 데이터의 노이즈가 많고 장기적인 패턴을 잘 반영하지 못하는 경향이 있어, 실질적인 투자 전략 수립에는 적합하지 않다는 비판이 제기되었다.

또한 기존의 전통적 통계 기법, 머신러닝, 딥러닝 기법은 텍스트 데이터와 이미지 데이터를 분리하여 다루게 된다. 이는 데이터의 유형에 따라 다른 처리 방식과 모델 아키텍처가 필요하기 때문이다. 치밍위안 외(2022)의

연구에서는 뉴스 이벤트와 주식 차트 데이터를 활용해 딥러닝 기반 주가 예측을 시도했다. 하지만 뉴스 이벤트는 차트와 함께 CNN 기반 모델의 입력 값으로 사용하기 위해 텍스트 형태가 아닌 이미지 형태로 추출되었다. 이러한 방식은 창의적인 접근이지만, 텍스트 기반의 자연어 처리(NLP) 모델을 활용하지 않음으로 인해 구문적, 의미적, 맥락적 정보를 정밀하게 분석하는데 한계가 있어 모델의 성능에 제약을 줄 수 있다.

이에 본 연구에서는 선행연구에서 확인된 한계를 극복하고자 Large Language Models(LLM)을 활용하여 멀티모달 데이터 기반의 주가 예측을 시도하며, 복잡한 시장의 다양한 요인들을 포괄적으로 분석하고 학습할 수 있는 새로운 접근 방식을 제안한다. Tabular, 텍스트, 이미지의 다양한 데이터 유형을 통합 처리하고 여러 시간 범위에 따른 경제 상황에 대한 데이터를 제시하여 시장의 다양한 상황에 대한 대응력을 강화시켜 기존 주가 예측 모델의 한계를 보완하고자 한다.

2.2. LLM 을 활용한 최근 연구 동향

Lopez-Lira et al. (2023)의 연구에서는 대형 언어 모델(Large Language Models, LLM) 중 특히 Chat GPT 가 뉴스 헤드라인을 분석하여 주식 시장의 수익률을 예측할 수 있는지를 평가한다. 연구의 주된 발견은 Chat GPT 가 긍정적 또는 부정적 뉴스를 평가하여 해당 주식의 다음 날 주가 움직임을 예측할 수 있으며, 이는 기존의 감정 분석 방법보다 우수한 결과를 나타낸다는 것이다. Chat GPT 를 이용한 장단기 트레이딩 전략을 평가한 결과, 뉴스가 긍정적인 점수를 받은 주식을 사고 부정적인 점수를 받은 주식을 파는 전략이 높은 수익률을 기록했으며, 특히 부정적 뉴스에 대한 반응이 더 강력한 예측력을 보인다. 이는 시장 참여자들이 부정적인 뉴스에 더 민감하게 반응한다는 것을 보여준다. 또한, GPT-4 는 더 복잡한 뉴스 해석에서 높은 예측 정확도를 보였으며, 다른 기본 모델들(GPT-1, GPT-2, BERT 등)과 비교할 때 상대적으로 높은 샤프 비율(Sharpe ratio)과 낮은 최대 낙폭(maximum drawdown)을 기록했다. 이는 Chat GPT 4 가 금융 시장에서 유용한 도구로 사용될 수 있음을 시사한다. Chat GPT 가 언어 이해 능력을 바탕으로 뉴스 헤드라인에서 중요한 정보를 추출하여 주가 움직임을 예측할 수 있는 능력을 입증함으로써, 기존의 텍스트 분석 기법들을 능가하는 새로운 접근 방식을 제시한다. 이러한 결과는 LLM 을 금융 결정 과정에

통합함으로써 투자 결정의 정확도와 거래 성능을 향상시킬 수 있다는 점을 강조한다.

Yu et al. (2023)의 연구에서는 대규모 언어 모델(Large Language Models, LLMs)을 이용하여 주가 시계열 예측의 가능성을 탐구한다. LLM 의 지식 및 추론 능력을 활용하여 설명 가능한 예측을 달성하고자 하며 이는 전통적인 시계열 분석법과 머신러닝 모델을 사용하는 기존 방법들이 가진 한계를 극복하고자 하는 시도 중 하나이다. 특히, 연구팀은 NASDAQ-100 주식의 과거 주가 데이터, 기업 메타데이터, 경제 뉴스 데이터를 활용하였다. 여기서 GPT-4 와 Open LLaMA 와 같은 대규모 언어 모델을 사용하여 Zero-shot 및 Few-shot 추론 실험을 수행하였고, 이러한 실험을 통해 LLM 이 기존의 ARMA-GARCH 모델이나 Gradient Boosting Tree 모델과 같은 기존 방법보다 우수한 성능을 보여주었다. LLM 을 활용한 접근 방식은 여러 재무 시계열 데이터의 복잡한 상호 작용과 패턴을 이해할 수 있는 능력을 보여주었고, 특히 인간이 이해할 수 있는 방식으로 예측 결과를 설명할 수 있는 능력이 강조되었다.


Lopez-Lira et al. (2023) 및 Yu et al. (2023)의 연구가 보여준 LLM 의 금융 시장 데이터 처리 및 분석에서의 우수성은, LLM 이 기존 분석 도구들을 능가하는 성능을 발휘할 수 있음을 입증한다. 이들 연구는 LLM 이 뉴스 헤드라인과 같은 텍스트 데이터뿐만 아니라, 복잡한 시계열 데이터를

이해하고 예측하는 데 탁월한 능력을 가지고 있음을 보여주었다. 이전 연구들에서 확인된 LLM 의 뛰어난 성능과 다양한 금융 데이터에 대한 분석 능력을 바탕으로, 본 연구에서는 주식 예측을 위한 데이터 분석 도구로 LLM 그 중에서도 현 시점 기준 최신 모델인 GPT-4o 를 선정하게 되었다.

2.3. 언어모델에서의 프롬프트 기법 연구 동향

2.3.1. Multimodal Chain of Thought

멀티모달 Chain of Thought(CoT)의 개념은 LLM을 활용에 있어 문제 해결을 위한 텍스트와 이미지의 통합에 그 기반을 두고 있다. 텍스트와 이미지 입력을 모두 활용하여 멀티모달의 이해가 요구되는 작업을 처리하고 추론하며, 이 방법의 근거는 시스템이 객체들의 다양한 속성과 측면을 고려함으로써 인간과 같은 추론 과정을 모방할 수 있는 능력에 있다.




[그림 2-1. 멀티모달 CoT 프레임워크 개요 - Zhang et al. (2023)]

멀티모달 CoT 기법은 텍스트 프롬프트에 적용된 Chain of Thought(CoT) 기법을 진화시킨 것으로, Zhang et al. (2023)의 논문에서는 멀티모달 CoT에 대한 프레임워크를 소개한다. 기존 LLM(GPT-3.5)에 의존하지 않고, 10억 개 이하의 파라미터를 가진 언어 모델을 fine-tuning 하여 다양한 모달리티를

통합하는 멀티모달 CoT 모델을 개발하였다. 특히 T5 모델을 기반으로 텍스트와 이미지 데이터를 결합하여 더 나은 추론을 가능하게 하는 두 단계 프레임워크를 제안하였다. 언어적 프롬프트와 시각적 특성을 결합하여 서로 다른 객체들의 유사점과 차이점을 식별하고 결정 과정을 정보화 하는데 있어 LLM 의 멀티모달 이해의 잠재력에 대한 검토를 제공한다. 예시로 모델이 크래커와 프렌치 프라이의 이미지를 받고 두 옵션 '부드러운(soft)' 또는 '짭(salty)' 중 공통된 속성을 결정하는 과제를 보여준다. CoT 과정을 통해 모델은 시각적 입력과 텍스트 설명을 평가하여 두 객체 모두 부드럽지 않지만 짭 맛이 있다는 결론을 내린다. 이 예시를 통해 멀티모달 CoT 기법이 서로 다른 모달리티에 대한 미묘한 이해가 필요한 작업에서 추론의 해석 가능성과 정확성을 향상시킬 수 있다는 잠재력을 강조한다.

2.3.2. Self Evaluation

Self Evaluation 은 언어 모델이 스스로 생성한 답변의 정확성을 판단하고 평가하는 기능을 의미한다. 즉, LLM 이 특정 질문에 대해 답변을 생성한 후 그 답변이 올바른지 스스로 검토하는 과정이다. 이러한 과정은 모델이 생성한 내용에 대한 신뢰도를 수치화하고, 더 나은 정보를 제공하기 위해 선택적으로 내용을 생성할 수 있게 한다. Ren et al. (2023)이 제시하는 Self Evaluation 방식은 3 가지 주요 단계로 구성된다.



[그림 2-2. Self Evaluation 3 가지 방식 - Ren et al. (2023)]


첫 번째, '샘플링하고 선택하기(Sample and Select)'는 다양한 후보 답변을 제시하고, 언어 모델이 가장 가능성이 높은 답을 선택하게 한다. 두 번째, '샘플링하고 평가하기(Sample and Eval)'는 선택된 답변이 올바른지 언어

모델 스스로가 평가하도록 한다. 세 번째, '하이브리드(Hybrid)' 접근 방식은 앞의 두 방법을 결합하여 최종 답변을 결정한다. 모델은 답변의 가능성을 평가하고, 시퀀스 가능성 점수(sequence likelihood score)를 통해 최종 답변의 타당성을 스스로 평가한다.

예를 들어, '수박씨를 먹으면 어떻게 되나요?'라는 질문에 대해 모델은 여러 선택지를 생성하고, 가장 가능성이 높다고 생각되는 '소화되어 몸 밖으로 나간다.'라는 답변을 선택한다. 이후 모델은 Self Evaluation 메커니즘을 통해 이 답변이 정확한지를 평가한다. 하이브리드 접근법은 검토 과정을 통해 답변의 신뢰성을 강화한다.

Ren et al. (2023)의 논문은 Self Evaluation 메커니즘의 설계와 그 효과를 심층적으로 탐구하며 언어 모델이 더 정확하고 신뢰할 수 있는 정보를 생성하는 데 기여하고, 최종 사용자에게 제공되는 답변의 질을 개선하는 데 중요한 역할을 하였다.

2.3.3. Self Consistency



[그림 2-3. Self Consistency 3 단계 절차 - Wang et al. (2023)]

Wang et al. (2023) 연구의 Self Consistency 는 언어 모델이 추론 과정에서 일관된 답변을 생성하도록 하는 3 단계를 포함한다. 첫 번째 단계에서는 Chain-of-Thought(CoT) 프롬프팅을 사용하여 언어 모델에 질문을 한다. 이후 CoT 프롬프팅에서 'greedy decode'를 대체하여 언어 모델의 디코더에서 다양한 추론 경로를 샘플링한다. 마지막으로, 이러한 추론 경로를 종합하여 가장 일관된 답을 최종 답변 집합에서 선택한다.

모델이 여러 계산 경로를 제시하고 그 중에서 가장 일관된 답변을 선택하는 이 방법론은 언어 모델의 추론 과정에서 일관성을 높이는 데 기여한다. 복잡한 추론 문제에 있어 여러 가지 다른 사고 방식을 허용하며, 다양한 사고 방식이 유일한 정답으로 수렴되는 점을 이용한다.

Self Consistency 는 반복적 수행에 따라 Local Optimize 문제를 피하며, 단일 샘플링 생성의 확률적 특성을 완화하는 장점을 가진다. 특히, PaLM-540B 나 GPT-3 와 같은 모델을 사용할 때, Self Consistency 는 GSM8K, SVAMP, AQUA 등 여러 수리 및 상식 추론 벤치마크에서 탁월한 성능 향상을 보였으며 추가적인 인간의 주석이나 추가적인 훈련 없이도 사전 훈련된 언어 모델과 함께 즉시 사용할 수 있다.

이 방법은 복잡한 추론 작업에서 언어 모델의 추론 능력을 향상시키는 데 유용하며, 반복적인 예측과 선택 과정을 통해 답변의 일관성과 신뢰성을 높일 수 있는 가능성을 보여준다.

제 3 장 연구 방법

3.1. 사용 모델

본 연구에서는 텍스트와 이미지 데이터의 효과적인 처리 및 생성을 목적으로 GPT-4o 모델을 사용하였다.

GPT-4o 모델은 현재 2023 년 10 월까지의 데이터로 학습되었으며, 텍스트, 음성, 비전의 모든 면에서 GPT-4 모델과 대비하여 향상된 기능을 갖추고 있다. 특히 이 모델은 이미지 처리 영역에 있어 GPT-4 Vision 모델과 비교했을 때 이미지 이해 및 설명 생성 능력이 크게 개선되었다. GPT-4o 모델은 텍스트 생성과 분석, 데이터 시각화, 파일 업로드를 통한 요약 및 분석 지원 등 다양한 고급 도구를 제공하여 연구의 효율성을 높였다.

모델의 특징을 잘 파악하는 것은 본 연구에서 다양한 형태의 데이터를 효과적으로 처리하고 분석하는 데 중요하다. GPT-4o 모델은 텍스트, 음성, 비전의 모든 면에서 향상된 성능을 발휘하며, 이는 연구의 최신성을 보장하고 비용 측면에서도 효율성을 높이는 데 기여하였다.

3.2. 연구 대상

한국 주식 시장의 KOSPI 200에 포함된 기업들을 대상으로 분석을 수행하였다. 실험은 섹터와 기업 규모를 동시에 고려하면서 최소한의 실험 수로 최대한의 정보를 도출할 수 있는 2^k 요인 설계를 적용하였다. 총 8개의 섹터로 분류하였으며, 각 섹터에서 기업 규모에 따라 시가총액이 가장 높은 기업 1개와 가장 낮은 기업 1개를 선정하여 총 16개 기업을 분석 대상으로 삼았다.

섹터명	KOSPI 200 기업명	
	시가총액 높은 기업	시가총액 낮은 기업
정보기술	삼성전자	롯데에너지머티리얼즈
헬스케어	셀트리온	한올바이오파마
금융	기업은행	JB금융지주
소비재	현대차	명신산업
필수소비재	한국전력	삼양식품
산업재	대한항공	두산퓨얼셀
에너지 화학	LG화학	후성
통신서비스	KT	제일기획

[표 3-1. 분석 대상 기업 목록]


이러한 설계를 통해 섹터별 및 기업 규모별 예측 방향 정확도 차이를 비교하였고 섹터와 기업 규모가 예측에 미치는 영향을 분석하였다. 기업 선정 기준은 FnGuide에서 제공하는 업종별 순위 데이터를 기반으로 하였으며, 자산총계를 내림차순으로 정렬하여 각 섹터별로 기업을 선택하였다.

연구 대상의 선정 과정에서 조건은 수집하고자 하는 데이터가 모두 충족되어야 한다는 것이다. 본 연구에서 필요로 하는 모든 데이터 유형(재무제표, 사업보고서, 주가 변동 차트, 관련 뉴스 기사 등)이 해당 기업에 대해 누락 없이 완전히 제공되는 경우에만 연구 대상으로 고려하였다. 예를 들어, 어떤 기업의 경우 필요 데이터 중 일부 누락된다면 해당 기업은 대상에서 제외하고 다음 순위의 기업을 검토하였다.

예측에 사용된 GPT-4o 모델의 학습 데이터는 2023년 10월까지의 정보를 포함하고 있으므로 본 연구에서는 학습 기간에 포함되지 않은 2024년의 데이터를 예측 대상으로 선정하였다. 구체적으로 2024년 1월부터 5월까지 월말 영업일인 2024년 1월 31일, 2024년 2월 29일, 2024년 3월 29일, 2024년 4월 30일, 2024년 5월 31일을 예측일로 선택하였다.

3.3. 데이터 수집 및 전처리

연구 대상 기업에 대한 데이터 선정 과정에서는 Zhou et al. (2022) 연구의 'Least to most prompting' 기법에 기반한 데이터 수집 기준을 적용하였다. 먼저 이 방법론에 따라 주가 변동 예측이라는 복잡한 문제를 보다 간단한 하위 문제로 분해하였으며, 본 연구에서는 특히 다음 주의 '주가 변동 예측'을 중점적으로 다루었다. "다음 주 '주가 변동 예측'을 위해 풀어야 할 하위 질문을 만들어주세요."라는 프롬프트에 대하여 GPT-4o 모델은 [그림 3-1]과 같은 다양한 하위 질문을 제시하였다.



[그림 3-1. 주가 변동 예측 위한 하위 질문 생성]

하위 질문들은 주가 변동 예측에 중요한 다양한 요소들을 포함하며 각각 특정 분석 측면을 대표함에 따라 구체적인 데이터 유형을 식별할 수 있었다. 예를 들어, 하위 질문에서 '사업의 개요'는 기업의 사업 모델, 시장 위치, 경쟁 환경 등을 평가하기 위한 기초 데이터를 식별하는 데 중요하다. 이는 투자자들이 기업의 잠재력과 위험을 평가하는 데 필수적인 정보를 제공한다. 또한, 재무제표의 주요 지표는 기업의 재무 건전성, 수익성, 성장 가능성 등을 분석하는 데 사용되며 시장에서의 기업 가치를 보다 정밀하게 평가할 수 있도록 돕는다. 기술적 분석을 위한 차트 지표와 주별 주가 변동률은 트렌드, 지지선, 저항선과 같은 중요한 시장 신호를 파악하는 데 기여할 수 있다. 최근의 주간 기업 뉴스와 경제 뉴스는 시장과 경제 환경의 변화를 신속하게 반영하는 정보 소스로 사용된다. 이러한 동적인 데이터는 투자 의사결정 과정에서 타이밍과 시장 감성을 이해하는 데 중요한 역할을 한다. 마지막으로, 주가 차트 이미지와 같은 시각적 자료는 데이터를 보다 직관적으로 이해하고 해석하는 데 도움을 주며, 추가적인 인사이트를 제공한다. 이에 따라, GPT-4o 모델을 통해 도출된 하위 질문들을 기준으로 하여 각 하위 문제에 가장 적합하고 설명 가능한 데이터를 선별하고 수집하였다.

3.3.1. 사업보고서 내 ‘사업의 개요’

사업보고서 내의 ‘사업의 개요’ 섹션은 기업의 전체 사업 모델, 주요 사업 영역, 시장 환경, 경쟁 구조, 그리고 기업의 전략적 위치 등을 포괄적으로 이해할 수 있도록 작성되었다. DART(금융감독원 전자공시시스템)에서 제공되며, 사업연도(2023 년 1 월 1 일부터 2023 년 12 월 31 일)에 대한 자세한 정보를 포함한다. ‘사업의 개요’ 섹션은 기업의 비즈니스 모델, 시장 위치, 전략적 방향성 등을 종합적으로 파악할 수 있는 핵심적인 정보로 본 연구에서 이 정보는 주가 변동 예측에 있어 중요한 기초 자료로 활용되며, 기업의 재무적 성과와 시장 가치에 영향을 미치는 다양한 요소들을 이해하는 데 기여한다.


3.3.2. 최근 기업 뉴스

본 연구에서는 기업의 가치에 영향을 미칠 수 있는 주요 사건 및 변화를 파악하기 위해 최근 기업 뉴스의 분석을 실시하였다. 이를 위해 각 예측 일을 기준으로 2 주 전 시점부터 네이버에서 기업명을 검색하여 해당 기간의 주간 뉴스를 수집하였다. 네이버 뉴스 관련도 순으로 상위 5 개의 뉴스가 주간 단위로 선택되었으며, 각 뉴스들은 GPT-4o 모델을 통해 한국어로 150 자 이내로 요약되었다. 또한, 주간 단위로 선정된 각 5 개의 뉴스 요약들은 다시 GPT-4o 모델을 통해 150 자 이내로 종합 요약되었다. 이 과정은 프롬프트


input 사이즈를 줄임과 동시에 한 주간 발생한 주요 사건과 트렌드의 핵심을 추출하는 것을 목적으로 하였다.

3.3.3. 최근 경제 뉴스

경제 뉴스는 주식 시장과 관련된 경제적 사건 및 트렌드의 변화를 식별하고, 이를 주가 변동 예측 모델에 반영하는 중요한 요소이다. 최근 기업 뉴스와 동일한 조건으로 각 예측일 기준 2주 전 시점부터 네이버 증권 사이트를 통해 해당 기간 동안의 일일 경제 뉴스를 수집하였다. 경제 뉴스의 경우 관련도 순 기준이 별도로 제공되지 않아 기간 내 매일 발행되는 네이버 증권의 주요 뉴스를 전체 수집하였으며, 이 뉴스들은 Gensim 라이브러리를 활용해 전체 원본 텍스트의 1% 길이로 요약하였다. 이는 하루 동안의 주요 경제 뉴스 약 200 개를 효과적으로 요약하기 위한 설정이다. 주간 단위로 수집된 일일 경제 뉴스의 요약은 다시 한번 Gensim 라이브러리를 통해 원본 텍스트의 0.05% 길이로 요약되며, 한 주간 발행된 경제 뉴스의 핵심 사건과 트렌드를 추출하여 주가 변동에 영향을 미칠 수 있는 중요한 경제적 요인을 식별하는 것을 목적으로 한다. 마지막으로 주간 경제 뉴스 요약의 최적화는 GPT-4o 모델의 통해 수행되며, 이는 요약의 질을 개선하고 더 명확하고 응집력 있는 요약을 생성하기 위한 과정이다.



[그림 3-2. LLM 을 활용한 최근 기업 뉴스 요약 프로세스]



[그림 3-3. Gensim을 활용한 최근 경제 뉴스 요약 프로세스]

3.3.4. 재무제표 주요 지표

본 연구에서 선정한 재무제표 주요 지표는 FnGuide 에서 제공하는 정보를 기반으로 하며, ‘재무제표’, ‘재무비율’, ‘투자지표’ 등의 분야에서 2023 년 12 월 기준으로 수집되었다. 연구에서 활용한 주요 지표로는 Hájek et al. (2013) 연구에서 주가에 유의미한 영향을 미친다고 확인된 PER (Price Earnings Ratio), Δ ROE (Return on Equity), ROC (Return on Capital), Δ Pre-tax operating margin, 및 Δ Non-cash working capital 이 있다. 이들 지표는 기업의 수익성, 효율성, 시장 가치 등을 평가하는 데 중요한 요소로, 본 연구의 주가 변동 예측에 핵심적인 데이터로 활용된다.

3.3.5. 주가 데이터

각 예측 일을 기준으로 8 주 전의 시점부터 yfinance 라이브러리를 통해 주가 데이터 세트를 수집하였다. 이 데이터 세트는 각 주식의 시가(Open), 고가(High), 저가(Low), 종가(Close), 수정 종가(Adj Close), 거래량(Volume)을 포함한다. 류형선 외(2013)에서 주가와 인과관계가 확인된 거래량 데이터를 포함하여 해당 데이터들은 특정 기간 내 주식 거래 패턴과 시장 반응을 분석하는 데 필수적이며, 주가의 단기적 변동 및 장기적 추세 예측에 활용될 수 있다.

3.3.6. 차트 지표

차트 지표의 경우 차트 이미지 분석의 보조 자료로 활용될 수 있도록 준비되었으며 각 예측 일을 기준으로 8 주 전 시점부터의 데이터를 사용하였다. 지표로 RSI (Relative Strength Index), SMA (Simple Moving Average), MACD (Moving Average Convergence Divergence)가 있으며, 이는 주식 시장의 기술적 분석에 중요한 역할을 한다.

- RSI 는 과매수 또는 과매도 상태를 나타내며, 시장의 강세나 약세 추세를 판단하는 데 사용된다.
- SMA 는 주가 변동의 일반적인 추세를 식별하기 위해 사용되는 가격의 이동 평균을 나타낸다.
- MACD 는 시장의 추세 전환점을 예측하는 데 사용되는, 단기 이동 평균과 장기 이동 평균의 차이를 나타낸다.

이러한 지표들은 지난 1년간의 데이터를 기반으로 장기적인 시장 추세 및 가능한 변동 포인트를 식별하는 데 도움을 준다.

3.3.7. 주별 주가 변동을

주별 주가 변동률은 동일한 8주간의 데이터를 기반으로 분석되었다. 이 분석은 전주 금요일의 종가 대비 해당 주의 주가 상승 및 하락 정도를 나타내며, 주가 변동을 "D5-", "D5", "U5", "U5+" 등으로 구간 카테고리화하여 표현한다. 변동률은 반올림 처리되었으며 각 구간의 명확한

정의를 내려 일관성을 유지하였다. 예를 들어, “D1”은 주가가 0.5% 이상 1.5% 미만 하락한 경우를, “U2”는 주가가 1.5% 이상 2.5% 미만 상승한 경우를 나타낸다. 또한 "D5-"는 주가가 5.5% 이상 하락한 경우를, "U5+"는 5.5% 이상 상승한 경우를 나타낸다. 주가의 단기적 추세에 대해 구간 카테고리화함으로써 주가 변동을 세밀하게 분석하고 이후 예측의 근접도를 평가할 수 있도록 하였다.

3.3.8 주가 차트 이미지

주가 변동과 시장 추세를 시각적으로 분석하기 위해 주가 차트 이미지를 생성하였으며 `mplchart` 라이브러리와 `yfinance` 라이브러리를 사용하였다. 차트는 주식 시장에서 특정 기업의 주가 움직임을 이해하는 데 필수적인 도구로, 복잡한 시장 데이터를 직관적으로 파악할 수 있도록 돕는다. 각 예측일을 기준으로 1년치 데이터를 기반으로 생성되었으며, 차트의 규격은 1200x900 으로 설정되었다. 차트의 해상도는 100x100 이고, 이미지의 파일 크기는 약 137KB 이다.



삼성전자 005930.KS (2023/01/29 ~ 2024/01/21)

[그림 3-4. 추출한 주가 차트 이미지]

3.4. 평가 방법

본 연구에서 주가 변동 예측에 대한 평가는 아래 2 가지 주요 지표를 통해 이루어진다 : 1) Direction Accuracy 와 2) Bin Score

예측 모델의 성능을 정량적으로 측정하고, 실제 시장 데이터에 대한 모델의 예측 정확도를 평가하는 데 사용된다.

3.4.1. Direction Accuracy

Direction Accuracy 는 예측된 주가 방향과 실제 주가 방향의 일치도를 측정하는 척도로, 주가가 상승(Up), 하락(Down), 또는 변동 없음(No Change)의 세 가지 상태로 구분될 때 모델이 주가 방향을 얼마나 정확히 예측할 수 있는지를 나타낸다. 이 지표는 모델의 시장 추세 예측 능력을 평가하는 데 중요하며, 예측된 주가 방향과 실제 주가 방향의 일치율이 높을수록 모델의 예측 정확도가 높다고 평가된다.

3.4.2. Bin Score

Bin Score 는 예측 값과 실제 값 간의 근접성에 기반하여 점수를 부여하는 방법으로, 구간(Bin) 카테고리화르 통해 주가 변동 범위를 세분화한다. 전주 금요일 종가 대비 주가의 상승 및 하락 정도를 분석하여 “D5-” 부터 “U5+” 까지 13 개의 구간 카테고리 중 선정하며, 실제 값과 비교해 예측 근접도 점수를 매긴다. 이 점수는 모델이 주가 변동의 정도를 얼마나

정밀하게 예측할 수 있는지를 나타내며, Bin Score 가 높을수록 모델의 예측 성능이 우수함을 의미한다. 실험 결과 해석 과정에서 평균 값이 극단 값에 의해 왜곡되어 대표성을 떨어뜨리는 문제를 방지하기 위해, Bin Score 계산 시 절사 평균을 사용하였으며 가장 높은 점수와 가장 낮은 점수를 제외하여 계산함으로써 보다 신뢰할 수 있는 평균값을 얻고자 하였다.

이 2 가지 평가 방법은 본 연구의 주가 변동 예측이 실제 시장 상황과 어느 정도 일치하는지, 그리고 시장의 변동을 얼마나 정확히 예측할 수 있는지를 종합적으로 평가하는 데 사용된다. Direction Accuracy 는 모델이 주가 변동의 방향성을 얼마나 잘 예측하는지를, Bin Score 는 변동의 정도를 얼마나 정확히 예측하는지를 나타낸다.

제 4 장 실험 및 결과

4.1. 실험 설계

LLM 을 활용한 주가 변동 예측을 위해 Zhou et al. (2022)의 방법론을 참고하여 복잡한 문제를 하위 문제로 분해하고 이미지 데이터, 텍스트, 그리고 Tabular 데이터를 순차적으로 제공하였다. 각 단계에서 입력 데이터가 점진적으로 증가하는 방식으로 예측을 수행하였다.

첫 단계에서는 이미지 데이터만을 입력으로 주가 변동 예측을 시도하였다. 이미지 내의 패턴과 특징을 분석하고, 이를 바탕으로 주가 변동을 예측하였다. 이후 단계에서는 이미지 데이터로 예측한 결과에 텍스트와 Tabular 데이터를 추가하여 설명 가능한 근거와 함께 주가 변동 예측을 수행하였다. 마지막으로 예측 근거 및 결과를 바탕으로 추가적인 프롬프트 기법을 적용하여 한번 더 예측을 시도하였다.

단계 1. 이미지 데이터 기반 예측


단계 2. 이미지, 텍스트, Tabular 데이터 기반 예측

단계 3. 수행한 예측에 대한 Self Evaluation


단계 4. 수행한 예측에 대한 Self Evaluation, Zero-shot CoT, 최종 예측

단계 3에서는 Ren et al. (2023)의 연구를 참고하여 모델이 스스로의 답변을 평가하는 기법을 도입하여 복잡한 문제에 대한 예측의 정밀도를 높였다. 단계 4에서는 Xu et al. (2023)의 방법을 참고하여 초기 질문을 작성하고 상기시키며 Yang et al. (2023)의 Zero-shot Chain of Thought(CoT) 기법을 추가하였다. Zero-shot CoT 기법에서는 최근 연구에서 가장 높은 정확도를 보였던 “깊게 숨을 쉬고 문제를 차례대로 풀어보자”라는 문구를 프롬프트에 적용하였다.

본 연구는 Zhang et al. (2023)의 멀티모달 프레임워크를 참고하여 설계되었으며, 각 단계는 주가 변동 예측의 정확도를 높이기 위해 다양한 모델링 기법을 결합하여 최적화되었다. 이러한 접근법은 여러 유형의 입력 데이터를 효과적으로 처리하는 데 중점을 두고 있다.




[그림 4-1. 이미지, 텍스트, Tabular 데이터 기반 LLM을 이용한 예측]




[그림 4-2. Self-Evaluation, Zero-shot CoT, 최종 예측]


• Stage 1 : Decompose Question into Subquestions(LtM)



• Stage 2 : Sequentially Solve Subquestions(LtM)



• Stage 3 : Self Evaluation + Zero-shot CoT



[그림 4-3. 멀티모달 데이터 기반 주가 변동 예측 실험 개요]

4.2. 실험 결과

4.2.1. 섹터 및 기업별 Direction Accuracy

	기업명	평균	240131	240229	240329	240430	240531
정보기술	삼성전자	80%	1	1	1	0	1
	롯데에너지머티리얼즈	100%	1	1	1	1	1
헬스케어	셀트리온	80%	1	0	1	1	1
	한올바이오파마	40%	1	0	0	1	0
금융	기업은행	20%	1	0	0	0	0
	JB금융지주	40%	0	1	1	0	0
소비재	현대차	60%	0	1	0	1	1
	명신산업	60%	1	1	1	0	0
필수소비재	한국전력	60%	0	1	0	1	1
	삼양식품	100%	1	1	1	1	1
산업재	대한항공	0%	0	0	0	0	0
	두산퓨얼셀	40%	0	1	0	0	1
에너지 화학	LG화학	20%	0	0	0	0	1
	후성	40%	1	1	0	0	0
통신서비스	KT	20%	0	0	1	0	0
	제일기획	60%	0	1	1	0	1

[표 4-1. 실험 결과 - 섹터 및 기업별 Direction Accuracy]

실험 결과에 따른 첫 번째 분석으로, 섹터별로 선정한 KOSPI 주요 기업들을 대상으로 각 기업의 월별 예측 방향의 정확도를 평가하였다.

예측 방향은 Up, Down, No Change 로 분류되며 실제 주가와 일치하는

방향으로 예측을 제시한 경우 1, 일치하지 않는 방향으로 예측을 제시한 경우 0 으로 나타내었다.

분석 결과, 정보기술 섹터에서는 롯데에너지머티리얼즈가 100%의 예측 방향 정확도를 보이며 가장 높은 성과를 기록하였고, 삼성전자도 80%의 높은 예측 방향 정확도를 나타냈다. 헬스케어 섹터의 셀트리온은 80%의 예측 방향 정확도를 나타내었고, 금융 섹터는 기업은행이 20%로 상대적으로 낮은 방향 정확도를 보였다. 소비재 섹터에서는 현대차와 명신산업이 각각 60%의 예측 방향 정확도를 기록하였다. 필수소비재 섹터의 한국전력은 60%, 특히 삼양식품은 100%의 예측 방향 정확도를 보였다. 산업재 분야에서는 대한항공이 0%로 예측 방향 정확도가 가장 낮았다. 에너지 화학 섹터의 LG 화학은 20%의 예측 방향 정확도를 나타냈으며, 통신서비스 섹터에서는 KT 가 20%, 제일기획이 60%의 예측 방향 정확도를 보였다.

이 결과는 섹터별로 예측 방향 정확도에 큰 차이가 있음을 시사하며 정보기술과 필수소비재 분야의 경우 예측 정확도가 높아 해당 섹터의 예측 능력이 상대적으로 우수함을 보여준다. 반면, 금융과 에너지 화학, 산업재 분야는 예측 정확도가 낮아 이들 분야에 대한 추가적인 연구와 프롬프트, 데이터 입력의 개선이 필요함을 의미한다.

4.2.2. 시가총액 기준별 Direction Accuracy

기업명	평균	240131	240229	240329	240430	240531	시가총액(원)
삼성전자	80%	1	1	1	0	1	469,224,908
현대차	60%	0	1	0	1	1	56,332,955
셀트리온	80%	1	0	1	1	1	39,622,963
LG화학	20%	0	0	0	0	1	25,907,390
한국전력	60%	0	1	0	1	1	12,621,014
시가총액 상위 5	60%						
기업은행	20%	1	0	0	0	0	10,613,738
KT	20%	0	0	1	0	0	9,160,988
대한항공	0%	0	0	0	0	0	8,229,732
삼양식품	100%	1	1	1	1	1	4,610,205
JB금융지주	40%	0	1	1	0	0	2,604,361
롯데에너지머티리얼즈	100%	1	1	1	1	1	2,536,096
시가총액 중간 6	47%						
제일기획	60%	0	1	1	0	1	2,094,901
한올바이오파마	40%	1	0	0	1	0	1,760,510
두산퓨얼셀	40%	0	1	0	0	1	1,519,454
후성	40%	1	1	0	0	0	853,752
명신산업	60%	1	1	1	0	0	811,188
시가총액 하위 5	48%						

[표 4-2. 실험 결과 - 시가총액 기준별 Direction Accuracy]

실험 결과에 따른 두 번째 분석에서는, 섹터별로 선정한 KOSPI 주요 기업들을 시가총액 기준으로 상위, 중간, 하위로 분류하였다. 상위 5개 기업(삼성전자, 현대차, 셀트리온, LG화학, 한국전력), 중간 6개 기업(기업은행, KT, 대한항공, 삼양식품, JB금융지주, 롯데에너지머티리얼즈), 하위 5개 기업(제일기획, 한올바이오파마, 두산퓨얼셀, 후성, 명신산업)으로 구성하였다. 섹터 및 기업별 Direction Accuracy 분석과 동일하게 예측 방향은 Up, Down, No Change로 분류되며 실제 주가와 일치하는 방향으로 예측을 제시한 경우 1, 일치하지 않는 방향으로 예측을 제시한 경우 0으로 나타내었다.

분석 결과, 시가총액 상위 5개 기업에서는 삼성전자와 셀트리온이 80%의 예측 방향 정확도를 보이며 가장 높은 성과를 기록하였다. 현대차와 한국전력은 60%, LG화학은 20%의 예측 방향 정확도를 나타냈다. 특히 삼성전자는 시가총액이 가장 큰 기업으로서 높은 예측 방향 정확도를 보인 반면, LG화학은 상대적으로 낮은 예측 방향 정확도를 기록하여, 시가총액이 반드시 예측 방향 정확도와 비례하지는 않음을 보여준다.

시가총액 중간 6개 기업에서는 롯데에너지머티리얼즈와 삼양식품이 100%의 예측 방향 정확도를 보이며 가장 높은 성과를 기록하였다. 반면, 대한항공은 0%로 가장 낮은 예측 방향 정확도를 보였다. JB금융지주는 40%, 기업은행과 KT는 각각 20%의 예측 방향 정확도를 기록하였다. 중간 그룹에서는 예측 방향 정확도의 편차가 크며, 일부 기업은 매우 높은 정확도를 보인 반면, 일부는 낮은 정확도를 보였다.

시가총액 하위 5개 기업에서는 제일기획과 명신산업이 60%의 예측 방향 정확도를 보였으며, 한올바이오파마와 두산퓨어셀, 후성은 각각 40%의 예측 방향 정확도를 기록하였다. 이는 하위 그룹에서의 예측 방향 정확도가 상대적으로 균등하게 분포됨을 시사한다.

이와 같은 결과는 시가총액별로 예측 방향 정확도에 차이가 있음을 보이며, 시가총액 상위 그룹의 경우 예측 방향 정확도가 평균 60%로 높지만 중간과 하위 그룹에서는 평균 47%, 48%로 예측 방향 정확도가 낮은 경향을 보였다.

4.2.3. 섹터 및 기업별 Bin Score

	기업명	평균	섹터평균	240131	240229	240329	240430	240531
정보기술	삼성전자	2.8	2.5	3	5	2	0	4
	롯데에너지머티리얼즈	2.2		2	0	2	4	3
헬스케어	셀트리온	3.4	2.6	3	3	5	1	5
	한올바이오파마	1.8		4	0	0	5	0
금융	기업은행	2	1.6	1	2	0	3	4
	JB금융지주	1.2		0	0	4	2	0
소비재	현대차	1.4	1.5	0	3	0	3	1
	명신산업	1.6		1	2	1	0	4
필수소비재	한국전력	2	2.3	0	3	0	3	4
	삼양식품	2.6		3	1	0	4	5
산업재	대한항공	1.6	1.7	1	1	1	1	4
	두산퓨얼셀	1.8		0	3	1	0	5
에너지 화학	(LG화학)	(0.6)	2.2	0	0	3	0	0
	후성	2.2		3	2	3	3	0
통신서비스	KT	1.4	1.4	0	1	3	1	2
	(제일기획)	(3.8)		2	5	4	3	5

[표 4-3. 실험 결과 - 섹터 및 기업별 Bin Score]

실험 결과에 따른 세 번째 분석에서는 섹터 및 기업별로 Bin Score의 평균을 계산하였다. 계산에 사용된 'Bin Score'는 예측값과 실제값의 일치도 및 근접도에 따라 점수를 부여하는 방식으로, 구간별 주가 변동 범위를 설정하여 전 주 종가 대비 상승 및 하락 정도에 대한 구간(D5- ~ U5+)선정 결과에 따라 점수를 산정하였다. 점수는 정확히 일치할 경우 5점, 구간 1개 차이는 4점, 2개 차이는 3점, 3개 차이는 2점, 4개 차이는 1점, 그 외에는 0점을 부여하였다. 최종적으로 가장 높은 점수와 가장 낮은 점수를 제외한 절사 평균을 사용하여 섹터별 예측 정확도를 평가하였다.

분석 결과, 정보기술 섹터에서는 삼성전자가 평균 2.8점, 롯데에너지머티리얼즈가 평균 2.2점을 기록하였으며, 섹터 절사 평균은 2.5점으로 나타났다.

헬스케어 섹터에서는 셀트리온이 평균 3.4점, 한올바이오파마가 평균 1.8점을 기록하였으며, 섹터 절사 평균은 2.6점으로 가장 높았다. 금융 섹터에서는 기업은행이 평균 2점, JB금융지주가 평균 1.2점을 기록하였고, 섹터 절사 평균은 1.6점을 기록했다. 소비재 섹터에서는 현대차가 평균 1.4점, 명신산업이 평균 1.6점을 기록하였으며, 섹터 절사 평균은 1.5점으로 나타났다. 필수소비재 섹터에서는 한국전력은 평균 2점, 삼양식품은 평균 2.6점을 기록하여 섹터 절사 평균 2.3점을 기록하였다. 산업재 섹터에서는 대한항공이 평균 1.6점, 두산퓨얼셀이 평균 1.8점을 기록하였으며, 섹터 절사 평균은 1.7점이다. 에너지 화학 섹터에서는 LG화학이 평균 0.6점이라는 최저 점수를 기록한 반면, 후성은 평균 2.2점을 기록하여 섹터 절사 평균은 2.2점이다. 마지막으로 통신서비스 섹터에서는 KT가 평균 1.4점, 제일기획이 평균 3.8점으로 최고 점수를 기록하였으며 섹터 절사 평균은 1.4점이다.

이 결과는 섹터별로 예측 정확도에 차이가 있음을 보여주며, 헬스케어 섹터와 정보기술 섹터가 높은 Bin Score 절사 평균을 기록하며 뛰어난 예측 정확도를 보였다. 특히 헬스케어 섹터의 셀트리온은 기업들 중 가장 높은 Bin Score 절사 평균을 기록하여 안정적인 예측 성능을 보였으며 정보기술 삼성전자 2.8점, 필수소비재 삼양식품 2.6점으로 뒤따랐다. 반대로, 금융과 통신서비스, 소비재 섹터는 낮은 Bin Score 절사 평균을 기록하여 예측이 어려운 섹터로 나타났다.

4.2.4. 시가총액 기준별 Bin Score

기업명	평균	240131			240229			240329			240430			240531			시가총액(원)
		정답	예측	Bin	정답	예측	Bin	정답	예측	Bin	정답	예측	Bin	정답	예측	Bin	
삼성전자	2.8	D2	D4	3	N	N	5	U4	U1	2	U3	D2	0	D3	D2	4	469,224,908
현대차	1.4	U5	N	0	U3	U5	3	D4	U1	0	U1	U3	3	D5	D1	1	56,332,955
셀트리온	3.4	D1	D3	3	U2	N	3	U2	U2	5	U5	U1	1	D2	D2	5	39,622,963
(LG화학)	(0.6)	(U5+)	(D4)	(0)	(D5-)	(U2)	(0)	(D2)	(N)	(3)	(U5+)	(D3)	(0)	(D5-)	(D1)	(0)	(25,907,390)
한국전력	2	U5+	D2	0	U5+	U4	3	D4	U2	0	D1	D3	3	D1	D2	4	12,621,014
시가총액 상위 5	2.4																
기업은행	2	U5	U1	1	U3	N	2	D5-	U1	0	U2	N	3	N	U1	4	10,613,738
KT	1.4	U5	D2	0	D2	U2	1	D3	D1	3	N	D4	1	U1	D2	2	9,160,988
대한항공	1.6	U1	D3	1	D2	U2	1	N	D4	1	U1	D3	1	N	U1	4	8,229,732
삼양식품	2.6	D5	D3	3	D5-	D2	1	U5+	U1	0	U4	U5	4	U5+	U5+	5	4,610,205
JB금융지주	1.2	U5+	D1	0	U1	U5+	0	D1	D2	4	U2	D1	2	U5+	N	0	2,604,361
롯데에너지머티리얼즈	2.2	D2	D5	2	D5-	D1	0	U3	U5+	2	D3	D4	4	U4	U2	3	2,536,096
시가총액 중간 6	1.83																
(제일기획)	(3.8)	(N)	(D3)	(2)	(D2)	(D2)	(5)	(U2)	(U1)	(4)	(U1)	(D1)	(3)	(D1)	(D1)	(5)	(2,094,901)
한올바이오파마	1.8	D5-	D5	4	D4	U1	0	D2	U5	0	U2	U2	5	D5-	U2	0	1,760,510
두산퓨얼셀	1.8	D4	U1	0	D5	D3	3	U2	D2	1	U5+	D4	0	D2	D2	5	1,519,454
후성	2.2	D5-	D4	3	D4	D1	2	N	U2	3	N	D2	3	U5+	D4	0	853,752
명신산업	1.6	D1	D5	1	D4	D1	2	D1	D5	1	U4	D4	0	U1	N	4	811,188
시가총액 하위 5	1.85																

[표 4-4. 실험 결과 - 시가총액 기준별 Bin Score]

실험 결과에 따른 네 번째 분석에서는 시가총액 기준별로 Bin Score의 평균을 계산하였다. 앞선 섹터 및 기업별 Bin Score 분석과 동일하게 가장 높은 점수와 가장 낮은 점수를 제외한 절사 평균을 사용하여 섹터별 예측 정확도를 평가하였다.

분석 결과, 시가총액 상위 5개 기업에서는 셀트리온이 평균 3.4점으로 가장 높은 성과를 기록하였다. 현대차와 삼성전자는 각각 평균 1.4점과 평균 2.8점, LG화학은 평균 0.6점, 한국전력은 평균 2점의 Bin Score를 나타냈다. 상위 그룹의 평균 Bin Score는 절사를 통해 2.4점으로 계산되었다. 시가총액 중간 6개 기업에서는 롯데에너지머티리얼즈가 평균 2.2점을 보였으며 삼양식품이 평균 2.6점을 기록하였다. 기업은행과 KT는 각각 평균 2점과 평균 1.4점, 대한항공과 JB금융지주는 각각 평균 1.6점과 평균 1.2점을 나타냈다. 중간 그룹의 평균 Bin Score는 절사를 통해 1.83점으로 계산되었다. 시가총액 하위 5개 기업에서는 제일기획이 평균 3.8점으로 가장 높은 점수를 기록하였다. 후성은 평균 2.2점, 두산퓨얼셀과 명신산업은 각각 평균 1.8점과 평균 1.6점, 한올바이오파마는 평균 1.8점을 기록하였다. 하위 그룹의 평균 Bin Score는 절사를 통해 1.85점으로 계산되었다.

이 결과는 시가총액에 따라 예측 정확도에 차이가 있음을 보여주며, 특히 시가총액 상위 기업들의 절사 평균 Bin Score가 높은 경향을 보였다. 시가총액이 클수록 더 높은 품질의 정보를 제공받을 수 있음에 따라 기업의 재무제

표와 사업보고서, 최근 뉴스 데이터에서 제공하는 정보의 질이 예측 성능에 영향을 미쳤음을 확인할 수 있다. Alshubiri(2021)의 연구에 따르면, 시가총액이 큰 기업들은 대체로 안정적인 재무상태와 일관된 성장 패턴을 보인다. 이러한 특성은 시가총액이 큰 기업의 주가 변동 예측을 더 정확하게 만드는 요인으로 작용할 수 있다.

제 5 장 결 론

5.1. 연구 결과 및 시사점

본 연구에서는 GPT-4o 모델을 활용하여 2024 년 1 월부터 5 월까지 매월 말 영업일을 기준으로 KOSPI 200 내 8 개 섹터의 총 16 개 기업의 주가를 예측하고 그 정확도를 평가하였다. 이를 통해 각 섹터별, 시가총액 기준별 주가 변동 예측의 정확성을 분석하고 LLM 의 금융 시장 예측 활용 가능성을 검토하였다.

모델의 입력 데이터로 이미지, 텍스트, Tabular 데이터를 통합 활용하였으며, 이러한 멀티모달 데이터 접근법이 주가 변동 예측의 정밀도를 높이는 데 효과적임을 확인하였다. 특히 Self Evaluation, Zero-shot Chain of Thought(CoT) 기법을 적용함으로써 예측의 깊이와 정확성이 향상되었으며, 이는 대규모 언어 모델(LLM)의 잠재력을 잘 보여주는 사례가 되었다.

주가 변동 예측 방향 정확도 및 근접도는 섹터별, 시가총액 기준별 Direction Accuracy 와 시가총액 기준별 Bin Score 로 측정하였다.

섹터별로 예측 방향 정확도를 분석한 결과, 정보기술 섹터와 필수소비재 섹터에서 높은 정확도를 기록하였다. 정보기술 섹터의 경우, 롯데에너지머티리얼즈가 100%의 예측 방향 정확도를 보였고, 삼성전자도 80%의 예측 방향 정확도를 나타냈다. 반면, 금융과 에너지 화학, 산업재 섹터는 정확도가 상대적으로 낮아 해당 섹터의 예측을 개선하기 위해 추가적인 연구와 데이터 입력 전략의 수정이 필요함을 시사한다.

시가총액에 따른 주가 변동 예측 방향 정확도는 다음과 같다. 시가총액이 큰 기업들이 상대적으로 높은 정확도를 보였다. 삼성전자와 셀트리온은 80%의 높은 예측 방향 정확도를 보였으며, 현대차와 한국전력은 60%의 예측 방향 정확도를 기록하였다. 반면, LG 화학의 경우 20%의 예측 방향 정확도를 보였는데, 일부 대형 기업이라도 산업 특성이나 특정 시점의 외부 변수에 따라 예측 성능이 달라질 수 있음을 보여준다. 중간 및 하위 시가총액 기업들의 경우 정확도가 상대적으로 낮았다. 대한항공은 0%의 예측 방향 정확도를 기록했으며, 기업은행과 KT 는 각각 20%의 예측 방향 정확도를 기록했다.

섹터 및 기업별로 예측 근접도를 Bin Score 로 계산하고 가장 높은 점수와 가장 낮은 점수를 제외한 절사 평균을 사용하여 섹터별 예측 정확도를 평가하였다. 분석 결과, 정보기술 섹터에서는 삼성전자가 평균 2.8 점, 롯데에너지머티리얼즈가 평균 2.2 점을 기록하였으며, 섹터 절사 평균은

2.5 점으로 나타났다. 헬스케어 섹터에서는 셀트리온과 한올바이오파마가 각각 평균 3.4 점, 평균 1.8 점을 기록하여 섹터 절사 평균은 2.6 점으로 가장 높았다. 반면, 소비재 섹터에서는 현대차가 평균 1.4 점, 명신산업이 평균 1.6 점을 기록하였고 섹터 절사 평균은 1.5 점이다. 통신 서비스 섹터는 KT가 평균 1.4 점을 기록하며 섹터 절사 평균이 가장 낮았다.

이 결과는 섹터별로 예측 정확도에 차이가 있음을 보여주며, 특히 정보기술 섹터의 삼성전자와 롯데에너지머티리얼즈는 모두 높은 Bin Score 를 기록하여 예측이 용이한 섹터로 나타났다. 헬스케어 섹터 또한 예측 정확도가 비교적 높게 나타났다. 특히 셀트리온은 기업들 중 가장 높은 Bin Score 절사 평균을 기록하여 안정적인 예측 성능을 보였다. 반대로, 소비재와 통신서비스 섹터는 낮은 Bin Score 절사 평균을 기록하여 예측이 어려운 섹터로 나타났다.

시가총액 기준으로 예측 근접도를 Bin Score 로 계산하고 가장 높은 점수와 가장 낮은 점수를 제외한 절사 평균을 사용하여 평가한 결과, 시가총액 상위 기업들이 상대적으로 높은 Bin Score 를 기록하였는데, 절사평균 Bin Score 2.4 로 가장 높은 성과를 기록하였다. 이는 시가총액이 클수록 더 높은 품질의 정보를 제공받을 수 있음에 따라 기업의 재무제표와 사업보고서, 최근 뉴스 데이터에서 제공하는 정보의 질이 예측 성능에 중요한 영향을 미쳤음을 확인할 수 있다.

종합적으로, 정보기술(삼성전자, 롯데에너지머티리얼즈) 섹터는 예측 방향성과 근접도 방면에서 모두 높은 정확도를 보였고 헬스케어(셀트리온, 한올바이오파마), 필수소비재(한국전력, 삼양식품) 섹터가 뒤를 이어 전반적으로 높은 예측 정확도를 나타냈다. 기업의 규모 관점에서 보았을 때에는 시가총액이 큰 기업일수록 대체적으로 예측 성능이 뛰어났다. 반면, 금융(기업은행, JB 금융지주), 산업재(대한항공, 두산퓨얼셀), 통신서비스(KT) 섹터와 시가총액이 상대적으로 낮은 기업일수록 예측 정확도가 낮게 나타났다. 따라서 예측 성능을 향상시키기 위해서는 기업 규모와 섹터에 특화된 데이터를 추가로 수집하고 이를 최적화해야한다. 이를 바탕으로 기업 규모와 섹터별로 적합한 데이터 및 프롬프트를 설계하여 추가 실험을 진행할 필요가 있다.

본 연구는 GPT와 같이 범용적인 데이터로 학습된 모델을 활용하여 금융 시장에서의 심층적인 분석이 가능함을 확인하였다. 또한 실제 금융 시장의 데이터는 숫자 뿐만 아니라 시장 감성, 경제 상황 변화, 뉴스 보도 등 비정형으로 다양한 정보를 포함하고 있으며 본 연구의 실험을 통해 LLM을 활용함으로써 다양한 데이터 유형을 통합하여 폭넓은 예측이 가능함을 보여준다. 이는 복잡한 금융 시장의 동향을 분석하고 실질적인 투자 결정에 중요한 영향을 미치는 설명 가능한 예측을 제공할 수 있을 것으로 기대된다.

이 연구는 고급 머신러닝이나 딥러닝 기술을 구체적으로 구현하지 않아도, 적절한 프롬프트를 설계함으로써 누구나 복잡한 분석을 수행할 수 있음을 보여준다. 이는 인공지능의 접근성을 향상시키며, 다양한 사용자가 복잡한 데이터를 이해하고 활용할 수 있는 길을 열어준다. 이러한 접근은 특히 금융 분야에서의 의사 결정과 같이 정보에 기반한 결정이 중요한 상황에서 매우 유용하다. 이는 LLM 기반의 예측 연구가 금융 분야뿐만 아니라 다양한 분야로의 적용 가능성을 확장하고 있음을 시사한다. 본 연구는 입력 데이터의 다양성 및 프롬프트의 중요성을 강조하며, LLM 기반 예측 연구가 산업군별로 어떻게 적용될 수 있는지를 보여주는 중요한 선례가 되기를 기대한다.

실험 결과를 바탕으로 본 연구는 다음과 같은 기대효과를 가지고 있다:

1. 새로운 주가 변동 예측 방법 제시: 본 연구는 GPT-4o 모델을 활용하여 멀티모달 데이터 분석을 통해 기존의 주가 변동 예측 방법론과 차별화된 새로운 접근법을 제안한다. 이미지 데이터, 텍스트 데이터, 그리고 Tabular 데이터를 결합함으로써 전통적인 단일 모달 분석 방식에서 간과되기 쉬운 패턴과 정보를 발견할 수 있다. 이러한 다차원적 접근은 주가 변동 예측의 설명 가능성을 높이는 동시에 LLM을 활용한 예측이 특정 섹터나 기업에서 특히 유효할 수 있는 경우를 파악하는데 기여할 수 있다.
2. 복잡한 데이터 분석 방법론의 혁신: 본 연구는 다양한 시간적 범위와 형태를 가진 데이터를 통합하여 분석 및 예측하는 새로운 방법론을

실험적으로 검증하였다. LLM 의 활용은 기존의 전통적인 데이터 분석 접근법에서는 어려웠던 유연성을 향상시킨다. 이를 통해 다양한 데이터 소스에서 얻은 정보를 최대한 활용하고 복잡한 문제에 적용함으로써 분석 및 예측 방법론 발전에 기여할 수 있을 것으로 기대된다.

3. 프롬프트 엔지니어링에 대한 이해 증진: 본 연구는 멀티모달 데이터에 대한 입력을 효과적으로 처리하는데 중점을 두어 다양한 프롬프트 기법을 결합하여 실험해봄으로써, LLM 을 활용한 분석에서 다양한 형태의 정보를 효과적으로 전달할 수 있는 프롬프트 엔지니어링의 중요성을 강조한다.

예측의 정확도를 높이기 위해 검증된 여러가지 프롬프트를 결합하는 접근 방식은 정보 전달의 정확성과 분석의 효율성을 높일 수 있을 것으로 기대된다.

4. 산업 분야에서의 AI 응용 연구 확대: 본 연구는 금융 분야, 특히 주가 변동 예측에서 LLM 의 적용 가능성을 탐구함으로써 실제 금융 예측 상황에서의 활용 예시를 제공한다. 이는 금융 시장 분석 및 투자 결정 과정에서 기술을 효과적으로 활용하는 방법에 대한 이해를 높이는 데 기여할 수 있다. 또한, 고급 머신러닝이나 딥러닝 기술을 직접 구현하지 않고도 적절한 프롬프트를 통해 복잡한 분석을 수행할 수 있음을 보여주며, 이는 인공지능의 접근성을 향상시키고, 다양한 사용자들이 복잡한 데이터를 활용할 수 있게 한다. 이 연구는 LLM 기반의 예측 연구가 다양한 분야로 확장될 가능성을 제시한다.

5.2. 한계 및 발전 방향

본 연구는 주가 변동 예측에 있어 몇 가지 한계점이 있다. 제시하는 한계들은 향후 연구의 방향성을 제시하는 데 중요한 역할을 한다.

첫째, 예측 날짜의 제한이다. 본 연구는 비용 문제로 인해 단 5 일을 대상으로 주 단위 주가 변동 예측을 진행했다. 이는 중요 이벤트가 발생하는 날짜를 포함한 다양한 시나리오에서의 성능을 검증하는 데 한계가 있다. 한계를 극복하기 위해 향후 연구에서는 월초, 월 중순, 그리고 특정 이벤트가 발생하는 여러 날짜에 대한 예측으로 시점에 따른 성능 비교 및 일반화 성능을 평가할 필요가 있으며, 일반화 성능 검증 시 실제 투자 결정에 더 큰 도움을 줄 수 있을 것이다.

둘째, 동일 섹터 및 관련 기업 정보 제공의 제한이다. 본 연구는 특정 기업의 데이터를 중심으로 실험을 설계하고 수행하여, 해당 기업의 데이터만을 사용하여 예측을 수행하였다. 따라서 관련 기업이나 동일 섹터에 속한 다른 기업들의 데이터를 프롬프트에 포함하지 않았다. 이는 섹터 내에서 연관성이 높은 기업들을 함께 고려하는 전략적 접근에는 한계가 있을 수 있다. 향후 연구에서는 다양한 기업 데이터를 통합하여 예측에 활용되는 데이터 범위를 확장하는 것이 중요하다. 이를 통해 예측의 범용성을 높이고, 다양한 섹터에서의 예측 유효성을 검증할 수 있을 것이다.

마지막으로, 데이터 입력 방식의 비효율성도 주요한 과제 중 하나다. 본 연구의 실험은 데이터를 직접 프롬프트에 입력하는 방식으로 구성되어 있으나, 이는 데이터 업데이트 과정에서 시간이 많이 소요되고 연구의 효율성을 저하시킨다. 향후 연구에서는 프롬프트 구성의 시스템화를 통해 최신 데이터를 반영할 수 있는 구조를 개발하는 것이 필요하다. 추후 Lewis et al. (2020) 연구의 Retrieval-Augmented Generation (RAG)의 개념을 도입하여, 연구에 필요한 최신의 주가 데이터를 실시간으로 검색하고 검증된 정보를 모델에 자동으로 입력하는 과정을 구현할 수 있다. 이러한 시스템의 개발은 데이터의 일관성과 신뢰성을 유지하며, 연구의 신속성과 정확성을 향상시킬 것이다.

이러한 한계점을 보완하는 연구 방향은 주가 변동 예측의 성능을 높일 뿐만 아니라, 금융 데이터 분석의 범위를 확장하는 데에도 기여할 수 있으며, 최종적으로는 투자자들에게 보다 신속하고 정확한 투자 결정 지원을 제공할 수 있을 것이다.

참고 문헌

국내 문헌

- [1] 류형선, 양성국, & 김봉현. (2013). 개별기업 주식의 거래량과 주가 간의 인과관계 검증: 한국주식시장을 중심으로 = A Test On Causality between Trading Volume and Stock Prices in the Individual Companies: Focusing on Korean Stock Market. 유라시아연구, 10(1), 305-325. 아시아유럽미래학회. ISSN: 1738-3382.
- [2] 박선영 & 송성주. (2024). LSTM 기반 주가 예측의 한계 및 개선 가능성에 대한 연구. 고려대학교 대학원, 석사학위논문, 통계적데이터과학 전공, 서울.
- [3] 신동하, 최광호, & 김창복. (2017). RNN 과 LSTM 을 이용한 주가 예측을 향상을 위한 딥러닝 모델. 한국정보기술학회논문지, 15(10), 9-16.
- [4] 주성준 & 오경주. (2024). LSTM 기반의 적대적 생성 네트워크(GAN)를 이용한 코스피 200 지수 방향 예측 = Prediction of KOSPI 200 Index Movement Using Generative Adversarial Network Based on LSTM. 연세대학교 일반대학원 석사학위논문, 산업공학과, 서울.
- [5] 치명위안 & 권오병. (2022). 뉴스이벤트 및 주식차트 기반 듀얼 이미지를 활용한 딥러닝 주가예측 방법. 경희대학교 대학원 석사학위논문, 경영학과, 서울.

- [6] 한경훈 & 추현승. (2023). K-평균 클러스터링을 이용한 데이터 증강 기반 심층 주가 예측에 관한 연구 = Research on deep stock prices prediction based on data augmentation using k-means clustering. 성균관대학교 일반대학원 석사학위논문, 소프트웨어학과, 서울.

해외 문헌

- [7] Ariyo, A. A., Adewumi, A. O., & Ayo, C. K. (2014). Stock Price Prediction Using the ARIMA Model. In Proceedings of the 2014 UKSim-AMSS 16th International Conference on Computer Modelling and Simulation (pp. 106-112).
- [8] Adams, G., Fabbri, A., Ladhak, F., Lehman, E., & Elhadad, N. (2023). From Sparse to Dense: GPT-4 Summarization with Chain of Density Prompting. arXiv preprint arXiv:2309.04269.
- [9] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., & Amodei, D. (2020). Language Models are Few-Shot Learners. arXiv preprint arXiv:2005.14165.

- [10] Chen, C., Xue, L., & Xing, W. (2023). Research on Improved GRU-Based Stock Price Prediction Method. *Applied Sciences*, 13(15), 8813.
- [11] Hájek, P., Olej, V., & Myšková, R. (2013). Forecasting stock prices using sentiment information in annual reports – A neural network and support vector regression approach. *WSEAS Transactions on Business and Economics*, 10(4), 293–305.
- [12] Hu, Z., Zhu, J., & Tse, K. (2013). Stocks market prediction using Support Vector Machine. In *Proceedings of the 2013 6th International Conference on Information Management, Innovation Management and Industrial Engineering* (Vol. 2, pp. 115–118). IEEE.
- [13] Kalyani, J., Bharathi, Prof. H. N., & Jyothi, Prof. Rao. (2016). Stock trend prediction using news sentiment analysis. *arXiv preprint arXiv:1607.01958*.
- [14] Khaidem, L., Saha, S., & Dey, S. R. (2016). Predicting the direction of stock market prices using random forest. *arXiv preprint arXiv:1605.00003*.
- [15] Lee, J., Kim, R., Koh, Y., & Kang, J. (2019). Global Stock Market Prediction Based on Stock Chart Images Using Deep Q-Network. *IEEE Access*, 7, 167260–167277. doi:10.1109/ACCESS.2019.2953542
- [16] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *arXiv preprint arXiv:2005.11401*.

- [17] Li, C., Wang, J., Zhang, Y., Zhu, K., Hou, W., Lian, J., Luo, F., Yang, Q., & Xie, X. (2023). Large Language Models Understand and Can be Enhanced by Emotional Stimuli. arXiv preprint arXiv:2307.11760.
- [18] Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2023). Lost in the Middle: How Language Models Use Long Contexts. arXiv preprint arXiv:2307.03172.
- [19] Li, K. (2022). Predicting Stock Price Using Convolutional Neural Network. In Proceedings of the 2022 IEEE International Conference on Artificial Intelligence and Computer Applications (pp. 739–742). IEEE. doi:10.1109/ICAICA54878.2022.9844607
- [20] Liu, J., Liu, A., Lu, X., Welleck, S., West, P., Bras, R. L., Choi, Y., & Hajishirzi, H. (2021). Generated Knowledge Prompting for Commonsense Reasoning. arXiv preprint arXiv:2110.08387.
- [21] Lopez-Lira, A., & Tang, Y. (2023). Can ChatGPT Forecast Stock Price Movements? Return Predictability and Large Language Models. arXiv preprint, arXiv:2304.07619.
- [22] Mehtab, S., Sen, J., & Dutta, A. (2020). Stock Price Prediction Using Machine Learning and LSTM-Based Deep Learning Models. arXiv preprint arXiv:2009.10819. doi:10.1007/978-981-16-0419-5_8
- [23] Qiao, S., Ou, Y., Zhang, N., Chen, X., Yao, Y., Deng, S., Tan, C., Huang, F., & Chen, H. (2022). Reasoning with Language Model Prompting: A Survey. arXiv preprint arXiv:2212.09597.
- [24] Rajagopal, D., Khetan, V., Sacaleanu, B., Gershman, A., Fano, A., & Hovy, E. (2021). Template Filling for Controllable Commonsense Reasoning. arXiv preprint arXiv:2111.00539.

- [25] Ren, J., Zhao, Y., Vu, T., Liu, P. J., & Lakshminarayanan, B. (2023). Self-Evaluation Improves Selective Generation in Large Language Models. arXiv preprint arXiv:2312.09300.
- [26] Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., & Zhou, D. (2022). Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv preprint arXiv:2203.11171.
- [27] Xu, B., Yang, A., Lin, J., Wang, Q., Zhou, C., Zhang, Y., & Mao, Z. (2023). ExpertPrompting: Instructing Large Language Models to be Distinguished Experts. arXiv preprint arXiv:2305.14688.
- [28] Xu, X., Tao, C., Shen, T., Xu, C., Xu, H., Long, G., & Lou, J.-g. (2023). Re-Reading Improves Reasoning in Large Language Models. arXiv preprint arXiv:2309.06275.
- [29] Xu, Y., & Cohen, S.B. (2018). Stock movement prediction from tweets and historical prices. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Long Papers) (Vol. 1, pp. 1970–1979). Association for Computational Linguistics. doi:10.18653/v1/p18-1183
- [30] Yang, C., Wang, X., Lu, Y., Liu, H., Le, Q. V., Zhou, D., & Chen, X. (2023). Large Language Models as Optimizers. arXiv preprint arXiv:2309.03409.
- [31] Yu, X., Chen, Z., Ling, Y., Dong, S., Liu, Z., & Lu, Y. (2023). Temporal Data Meets LLM -- Explainable Financial Time Series Forecasting. arXiv preprint arXiv:2306.11025.

- [32] Zhang, Z., Zhang, A., Li, M., Zhao, H., Karypis, G., & Smola, A. (2023). Multimodal Chain-of-Thought Reasoning in Language Models. arXiv preprint arXiv:2302.00923.
- [33] Zhou, D., Schärli, N., Hou, L., Wei, J., Scales, N., Wang, X., Schuurmans, D., Cui, C., Bousquet, O., Le, Q., & Chi, E. (2022). Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. arXiv preprint arXiv:2205.10625.
- [34] Alshubiri, F. (2021). The stock market capitalisation and financial growth nexus: an empirical study of western European countries. *Future Business Journal*, 7(1), 1–20. SpringerOpen. DOI: 10.1186/s43093-021-00092-7.

ABSTRACT

Multimodal Data-Based Large Language Model (LLM) for Stock Movement Prediction: A Focus on the South Korean Stock Market

Won, Jae Hee

Dept. of Industrial Information Management

The Graduate School of Engineering

Yonsei University

This study explores the potential of explainable predictions of stock price movements in the Korean stock market using Large Language Models (LLMs), particularly GPT, through multimodal data. This allows us to propose a new prediction approach that differentiates from existing prediction methodologies. Unlike previous research that focused on single-form data, this study integrates diverse data types such as text, image or tabular data for more flexible analysis of complex issues, aiming to expand LLM applications in financial market analysis and investment decision-making.

The study employs the latest GPT-4o model, comparing and evaluating

prediction accuracy from various perspectives such as company size and sector. The prediction dates are the last business days from January to May 2024. Prompt techniques were used within a multimodal CoT framework to find effective methods in a multimodal data environment.

Results indicate that the Information Technology, Health Care and Consumer Staples sectors show high accuracy, especially for larger market capitalization companies. Conversely, sectors like Financials, Industrials, and Communication Services, and smaller companies show lower accuracy. This variance highlights that there are differences in prediction accuracy based on company size and sector, indicating the need for specialized data and tailored prompts for different company sizes and sectors.

This study presents a new methodology for predicting stock price movement by effectively combining various data types, contributing to understanding and forecasting financial market trends. It demonstrates that with models like GPT, professional data analysis and explainable predictions are possible without advanced machine learning or deep learning knowledge. This suggests expanding the application of multimodal-based LLMs in data analysis and prediction across various fields, not just finance.

Keywords : Multimodal, LLM, GPT, Prompt Engineering, Stock Price Movement, KOSPI