

하이퍼그래프 기반의 근거 중심 토론과 이중 프로세스 지식 증류를 통한 협력적 트레이딩 시스템

Collaborative Trading System via Hypergraph-Grounded Debate and Dual-Process Knowledge Distillation

허상훈, 황영배¹⁾

Sanghun Heo, Youngbae Hwang

(28644) 충북 청주시 서원구 충대로 1 충북대학교

산업인공지능학과, 지능로봇공학과

{www.hunyc.com, ybhwang}@cbnu.ac.kr

요 약

현대 금융 시장은 거시경제 변수와 자산 간의 비선형적 상호작용이라는 '복잡성(Complexity)'과, 밀리초(ms) 단위의 빠른 대응이 요구되는 '즉시성(Immediacy)'이라는 두 가지 난제를 동시에 제시한다. 기존 대규모 언어 모델(LLM) 기반 멀티 에이전트 시스템은 뛰어난 추론 능력을 보였으나 환각(Hallucination) 현상과 느린 추론 속도라는 한계를 가지며, 강화학습(RL) 모델은 빠른 실행 속도에 비해 시장의 인과적 맥락을 파악하지 못하는 문제점을 안고 있다. 본 연구는 이러한 문제를 해결하기 위해 인지과학의 이중 프로세스 이론(Dual Process Theory)에 착안하여, "하이퍼그래프 기반의 근거 중심 토론과 이중 프로세스 지식 증류를 통한 초고속 협력적 트레이딩 시스템"을 제안한다. 제안하는 시스템은 숙고적 사고를 담당하는 System 2 (Teacher) 단계에서 동적 금융 하이퍼그래프를 구축하여 구조적 리스크를 정밀하게 추론하고, 이를 지식 증류(Knowledge Distillation) 기법을 통해 직관적 사고를 담당하는 System 1 (Student) 단계로 전이하여 경량화된 신경망을 통해 실시간 트레이딩을 수행한다. 주식 및 파생상품을 포함한 10년 치의 대규모 멀티모달 데이터 실험 결과, 본 모델은 복합 위기 상황에서 기존 최선(SOTA) 모델 대비 우수한 수익률(Sharpe Ratio 2.15)과 안정성(MDD -9.2%)을 달성하였다. 특히 추론 속도 측면에서 290배 이상의 성능 향상을 입증함으로써, 고성능 AI의 금융권 실무 적용 가능성을 확인하였다.

Abstract

Modern financial markets simultaneously present two challenges: 'Complexity,' arising from the non-linear interactions between macroeconomic variables and assets, and 'Immediacy,' requiring instantaneous responses at the microsecond (μ s) level. While existing Large Language Model (LLM)-based multi-agent systems have demonstrated superior reasoning capabilities, they are limited by hallucinations and slow inference speeds. Conversely, Reinforcement Learning (RL) models offer fast

1) 교신저자

execution but fail to grasp the causal context of the market. To address these issues, drawing inspiration from the Dual Process Theory in cognitive science, this study proposes a "High-Speed Collaborative Trading System via Hypergraph-Grounded Debate and Dual-Process Knowledge Distillation." In the proposed system, the System 2 (Teacher) stage, responsible for deliberative thinking, constructs a dynamic financial hypergraph to precisely infer structural risks. This knowledge is then transferred via Knowledge Distillation to the System 1 (Student) stage, responsible for intuitive thinking, enabling real-time trading through a lightweight neural network. Experimental results using 10 years of large-scale multimodal data, including stocks and derivatives, demonstrate that the proposed model achieved superior profitability (Sharpe Ratio 2.15) and stability (MDD -9.2%) compared to existing state-of-the-art (SOTA) models, particularly during complex crisis scenarios. Notably, the system demonstrated a performance improvement of over 290 times in inference speed, confirming the feasibility of applying high-performance AI in practical financial environments.

키워드: 동적 금융 하이퍼그래프, 이중 프로세스 이론, 지식 증류, 멀티 에이전트 시스템, 뉴로-심볼릭 AI, 멀티모달 금융 데이터

Keyword: Dynamic Financial Hypergraph, Dual Process Theory, Knowledge Distillation, Multi-Agent System, Neuro-Symbolic AI, Multimodal Financial Data

1. 서론

현대 금융 시장은 더 이상 단일 자산이나 특정 경제 지표의 선형적 인과관계만으로는 설명할 수 없는 고도의 복잡계로 진화하였다. 금리, 환율, 원자재 가격, 기업 실적 등은 복합적으로 얽혀 초고차원 (High-order) 상관관계를 형성하며, 이러한 비선형적 역학은 시장 예측을 더욱 어렵게 만든다. 이와 동시에 알고리즘 트레이딩의 발전으로 인해 시장은 정보 처리 속도의 우위가 수익을 결정하는 전장이 되었다.


그러나 현재의 금융 AI 연구들은 시장의 심층적인 맥락을 이해하는 '지능(Intelligence)'과 찰나의 기회를 포착하는 '속도(Latency)' 사이의 딜레마에 빠져 있다. TradeMaster[3]로 대표되는 강화학습 기반 모델은 빠르지만 뉴스나 공시와 같은 텍스트적 맥락을 이해하지 못하는 '블랙박스'의 한계를 지니며, TradingAgents[4]와 같은 LLM 기반 모델은 논리적 추론이 가능하나 연산 비용이 높고 느려 급변하는 호가창에 대응하기 어렵다는 단점이 있다.

본 연구는 인간의 인지 구조인 이중 프로세스 이론 (Dual Process Theory) [1]을 제안한 연구를 모방하여 상기한 딜레마를 해결하고자 한다. 또한, 뉴로-심볼릭 AI (Neuro-Symbolic AI) [5] 접근법을 적용하여 논리적 추론과 패턴 인식을 결합함으로써 시스템의 완성도를 높였다.

본 연구의 핵심 기여는 다음과 같다.

첫째, 속고적 사고 시스템인 System 2 (Teacher) 단계에서는 동적 금융 하이퍼그래프 (Dynamic Financial Hypergraph)를 구축한다. 이를 통해 에이전트들은 단순한 텍스트가 아닌, 시장의 N:N 복합 상관관계를 구조화한 하이퍼엣지 (Hyperedge)를 토론의 객관적 근거 (Grounding)로 활용한다. 이는 기존 에이전트들의 '말뿐인 토론'을 '데이터 증거 기반의 토론'으로 격상시켜 환각을 억제하고 논리적 정합성을 확보한다.

둘째, 직관적 사고 시스템인 System 1 (Student) 단계에서는 추론 증류 (Reasoning Distillation) [24] 기법을 도입한다. System 2의 고차원적 토론 과정과 의사결정 정책을 경량화된 신경망 모델로



(그림 1) 연구 프레임워크

압축 및 전이함으로써, System 1은 복잡한 연산 없이도 전문가적 직관을 모사하여 틱(Tick) 단위 데이터에 밀리초(ms) 단위로 반응할 수 있는 초고속 실행 능력을 갖춘다.


2. 관련연구

초기의 금융 AI 연구는 DQN, PPO 등 단일 에이전트 강화학습(Single-Agent RL)에 집중되었다. FinRL[6]이나 기존 고빈도 매매 모델[7]의 고빈도 매매 연구와 같은 초기 모델들은 수치 데이터 처리에 최적화되어 있으나, 비정형 텍스트 데이터에 내포된 인과관계를 파악하지 못하고 과적합(Overfitting)되기 쉬운 문제에 직면했다. 이를 극복하기 위해 최근 TradingAgents[4]와 같은 멀티 에이전트 시스템이 등장하여 에이전트 간의 '토론'을 통해 의사결정의 편향을 줄이고자 했다.

최근 BloombergGPT[8]와 FinGPT[9] 같은 금융 특화 LLM이 등장했다. 이를 활용하여 Trading GPT[10]나 Generative Agents[11] 연구에서도

볼 수 있듯이 LLM을 활용한 시도가 이어졌다. 그러나 반복적인 LLM 호출로 인해 발생하는 막대한 연산 비용과 수 초 이상의 추론 지연 시간은 실시간 매매 환경에서의 적용을 가로막는 주요 장벽으로 작용하고 있다. '생각의 사슬(Chain-of-Thought)' [12] 기법 등은 추론 능력은 높였으나 속도 문제를 해결하지 못했다.

한편, 금융 시장의 지식 표현에 주로 사용되던 단순 지식 그래프(Knowledge Graph)는 개체 간의 1:1 관계(Binary Relation)만을 표현할 수 있어, 금융 시장 특유의 다자간 상호작용(N:N)을 온전히 담아내지 못한다는 한계가 있다. 반면 하이퍼그래프 관련 선행 연구[13, 14]에서 알 수 있듯이, 하이퍼그래프(Hypergraph)는 하나의 엣지(Hyperedge)가 다수의 노드를 동시에 연결할 수 있는 구조를 가진다. 예를 들어 "금리 인상이 기술주와 채권, 환율에 미치는 동시 다발적 충격"과 같은 복합 리스크를 모델링하는 데 있어 하이퍼그래프는 필수적이다. 본 연구는 이러한 하이퍼그래프 신경망(HGNN)을 금융 시계열의 인과 추론에 적용하여 구조적 리스크



(그림 2) System 2: 동적 금융 하이퍼그래프 구축 파이프라인

를 파악한다. 한편, 추론 과정을 경량화하기 위해 단계별 추론 증류(Distilling Step-by-Step) [15]를 제안했으며, 의식적 사전 확률(Consciousness Prior) [16] 개념을 시스템 설계에 반영한 것이다.

3. 실험 방법

본 연구에서 제안하는 System 2는 이중 프로세스 이론[1]의 이중 프로세스 이론 중 인간의 '숙고적 사고(Slow, Deliberative Thinking)'에 해당하며, 실시간성보다는 추론의 정확도와 논리적 완결성, 그리고 구조적 리스크 파악을 최우선 목표로 한다.

3.1 동적 금융 하이퍼그래프 구축

본 연구는 금융 시장의 이질적인 멀티모달 데이터(뉴스, 가격, 거시지표)를 통합하기 위해, 하이퍼그래프 신경망(HGNN) [17, 18] 이론을 확장하여 동적 하이퍼그래프를 정의한다. 또한 학습 효율성을 위해 HyperGCN[19]의 방식을 차용하여 노드 간 정보를 전파한다. 시점 t 에서의 하이퍼그래프 H_t 는 다음과 같이 정의된다.

$$H_t = (V_t, E_t)$$


여기서 노드 집합 V_t 는 개별 주식, ETF, 파생상품 등의 '자산(Asset)', 금리 및 환율 등의 '거시지표(Macro)', 그리고 뉴스에서 추출된 정형화된 '이벤트(Event)'를 포함한다.

하이퍼엣지 생성 과정에서는 LLM의 고질적인 문제인 환각(Hallucination) 현상을 방지하기 위해 2단계 검증 프로세스를 도입하였다. 뉴스 텍스트 처리를 위해 FinBERT [20]를 사용하여 텍스트 임베딩을 생성한다. 우선 LLM이 뉴스 텍스트를 독해하여 잠재적인 인과관계 가설을 생성한다.

이후 전이 엔트로피(Transfer Entropy, TE) [21]를 계산하여 정보 흐름이 통계적으로 유의미한 경우, 즉 다음의 조건을 만족할 때만 해당 엣지를 그래프에 활성화한다.

$$TE_{X \rightarrow Y} > \theta$$

여기서 θ 는 유의미성을 판단하는 임계값이다. 이를 통해 텍스트만으로는 알 수 없는 실질적인 인과성을 수학적으로 검증한다.



(그림 3) System 2: 동적 금융 하이퍼그래프 구축 파이프라인

3.2 그래프 가중치의 동적 재할당

금융 시장의 상관관계는 고정되어 있지 않고 시장 국면(Regime)에 따라 급변한다. 본 시스템은 이를 반영하기 위해 그래프 어텐션 네트워크(GAT) [22]를 응용하여, 하이퍼엣지의 가중치 $w_e(t)$ 를 다음과 같이 동적으로 재할당한다.

구축된 하이퍼그래프의 연결 강도를 조절하기 위해, 엣지의 가중치 $w_e(t)$ 는 구조적 강도(S_{str})와 시장 국면(R_{att})을 결합하여 다음과 같이 계산된다.


$$w_e(t) = \alpha \cdot S_{str} + \beta \cdot R_{att}(S_t)$$

여기서 S_{str} 은 전이 엔트로피(TE) 등으로 계산된 구조적 강도를 의미하며, R_{att} 는 시장 국면(상승, 하락, 변동성 확대 등)에 따른 주의 집중 함수이다. S_t 는 시점 t 의 시장 국면을 나타낸다. 예를 들어 변동성 확대 국면에서는 VIX 지수와 연동된 '리스크 하이퍼엣지'의 가중치가 증폭되어, 에이전트들이 리스크 요인에 더욱 민감하게 반응하도록 유도한다.


3.3 근거 중심 토론 (Graph-Grounded Debate)

본 연구는 기존 멀티 에이전트 시스템의 주된 한계인 자유분방한 언어 생성에 따른 환각 문제를 보완하기 위해 '근거 중심 토론(Graph-Grounded Debate)'을 도입한다. Graph-Grounded Debate란 단순 텍스트 기반의 검색 증강(Retrieval-Grounded)이나 일반적인 추론(Grounded Reasoning)과 달리, 수학적으로 검증된 하이퍼그래프 상의 인과 경로(노드 간 TE 값 등)만을 논리적 근거로 제한하여 에이전트 간 토론을 진행하는 방식이다. 시장 분석가(Analyst) 에이전트는 하이퍼그래프 상의 전과 경로(Path)를 탐색하여 잠재적 기회 요인을 발굴하고, 리스크 관리자(Risk Manager) 에이전트는 '일관성 있는 위험 척도(Coherent Measures of Risk)' [23] 개념을 적용하여 꼬리 위험(Tail Risk) 노드와 연결된 엣지를 전담하여 감시한다.

특히, 모든 주장은 '하이퍼그래프 엣지 ID #42(금리 인상→기술주 하락 경로)에 따르면...'과 같이, 시스템 내부에서 생성된 구체적인 인과관계 식별자(ID)와 TE 값을 근거(Grounding)로 제시해야 하는 프로토콜을 따른다. 이는 에이전트 간의 합의 과정



(그림 4) 추론 증류 (Reasoning Distillation) 메커니즘




(그림 5) t-SNE 시각화 (Teacher vs Student Latent Space)

에서 발생할 수 있는 오류를 최소화하고 설명 가능성을 보장한다.


4. 실험 결과

본 연구에서 제안하는 System 1은 System 2의 고차원적 지능을 이어받아 실시간 시장 데이터에

즉각적으로 반응하는 경량화된 실행 모델이다. System 2의 심층적인 구조적 리스크 분석을 내재화한 System 1은, 추가적인 연산 부하 없이 밀리초(ms) 단위의 실시간 매매를 수행한다. 본 실험은 이러한 협력적 구조가 급변하는 실제 시장 환경에서 발휘하는 유효성을 검증하는 데 목적이 있다.



(그림 6) System 1: 초고속 실행 에이전트 구조



(그림 7) 비동기식 이중 프로세스 운용 전략

4.1 추론 증류 (Reasoning Distillation) 파이프라인

본 연구는 단순히 교사 모델의 결과값(Action)만을 모방하는 일반적인 지식 증류(Knowledge Distillation) [2]를 넘어, '추론 증류(Reasoning Distillation)' [24]가 제안한 '사고 과정(Reasoning)'

자체를 학습하는 추론 증류 기법을 제안한다. 이를 통해 System 1은 System 2의 결론뿐만 아니라 도출 경로까지 학습한다. System 1의 학습을 위한 총 손실 함수 L_{total} 은 다음과 같이 설계된다.

$$L_{total} = \alpha L_{task} + (1 - \alpha) T^2 L_{distill}$$

여기서 L_{task} 는 실제 시장 데이터(Ground Truth)와의 예측 오차를 줄이는 기본 학습 손실(MSE 또는 Cross-Entropy)이다. $L_{distill}$ 은 교사 모델의 정책(L_{policy})과 추론 경로 특징($L_{reasoning}$)을 포괄하는 증류 손실로, 다음과 같이 정의된다.

$$L_{distill} = D_{KL}(P_T \| P_S) + \lambda \| H_{graph} - H_{student} \|^2$$

여기서 D_{KL} 은 쿨백-라이블러 발산(Kullback-Leibler Divergence)이며, H_{graph} 는 System 2의 하이퍼그래프 임베딩, $H_{student}$ 는 System 1의 잠재 공간 벡터이다. α 는 시장 변동성에 따라 동적으로 조절되는 적응형 파라미터로, 변동성이 큰 위기 상황에서는 교사의 지침 비중을 높여 모델의 안정을 꾀하도록 설계되었다.

4.2 System 1 모델 구조 및 입력 데이터

System 1은 복잡한 그래프 연산 없이 밀리초 단위의 응답 속도를 보장하기 위해 최적화된 신경망 구조를 갖는다. 입력 데이터로는 틱 데이터(OHLC, VWAP), 오더북(호가창 불균형), 그리고 기술적 지표(RSI, MACD 등)가 사용된다. 또한 System 2에서 전달받은 시장 국면 및 리스크 정보를 담은 **컨텍스트 벡터(Context Vector)**가 비동기적으로 주입되어 모델의 판단을 돕는다.

모델 아키텍처는 시계열의 국소적 패턴을 추출하는 1D-CNN과 장기 의존성을 학습하기 위해 트랜스포머(Transformer) [25]를 경량화된 Tiny Transformer를 결합한 하이브리드 모델로 구성된다. 최종적으로 매수, 매도, 청산, 관망의 확률값 및 최적 호가를 출력한다.

4.3 비동기식 이중 프로세스 운용 전략

두 시스템은 서로 다른 시간 주기에서 작동하며 상호 보완적인 관계를 맺는다. **Fast Path**인 System 1은 매 틱(Tick)마다 실시간 매매를 수행하며, 평균 12ms 내외의 지연 시간을 유지한다. 반면 **Slow Path**인 System 2는 30분 주기 또는 주요 뉴스 발생이나 급등락과 같은 이벤트 트리거 시에만 활성화되어 하이퍼그래프를 갱신하고 전략을 수정한다. 이때 **‘이중 버퍼링(Double Buffering)’** 메커니즘을 적용하여, System 2가 학습하고 업데이트하는 동안 System 1은 구버전 가중치로 중단 없이 매매를 지속하고, 업데이트가 완료되는 즉시 새로운 가중치로 전환함으로써 트레이딩 공백을 방지한다.


5. 실험 및 성능 평가

5.1 실험 환경

제안하는 시스템의 성능을 검증하기 위해 2014년부터 2023년까지 10년 치의 S&P 500 및 NASDAQ 100 구성 종목의 주식, 파생상품(옵션), 뉴스, 거시경제 지표를 포함한 대규모 데이터셋을 활용하였다. 데이터셋은 2014년 1월부터 2020년 12월까지를 학습 데이터(Train), 2021년을 검증 데이터(Validation), 2022년부터 2023년까지를 테스트 데이터(Test)로 분할하였다. 뉴스 데이터는 Bloomberg와 Reuters의 금융 기사를 활용하였고, 거시경제 지표는 금리, CPI, VIX 등을 포함하여 구성하였다. 비교 모델로는 벤치마크인 Buy & Hold 전략, 강화학습 기반 SOTA 모델인 TradeMaster [3], 그리고 LLM 기반 SOTA 모델인 TradingAgents [4]를 선정하였다. 비교 모델로 선

〈표 1〉 모델 성능 비교 (수익성 및 리스크)

모델 (Model)	누적 수익률 (CR)	샤프 지수 (Sharpe Ratio)	최대 낙폭 (MDD)	승률 (Win Rate)
Rule-based (Buy & Hold)	12.5%	0.85	-24.8%	N/A
TradeMaster (RL-Based)	28.4%	1.45	-15.2%	53.2%
TradingAgents (SOTA)	34.1%	1.68	-18.5%	55.4%
Proposed (Ours)	42.5%	2.15	-9.2%	61.8%



(그림 8) 수익률 및 MDD 비교 (Equity Curve)

정된 TradingAgents[4]의 경우 2024년 사전 출판 논문(arXiv preprint)이나, 급격히 발전하는 LLM 기반 금융 AI 분야의 최신 멀티 에이전트 구조의 동향(SOTA)을 가장 잘 반영하고 있어 주요 비교군으로 포함하였다.

5.2 정량적 성과 분석


〈표 1〉의 모델 성능 비교 결과에 따르면, 제안 모델(Proposed)은 누적 수익률(CR) 42.5%, 샤프 지수(Sharpe Ratio) 2.15를 기록하며 기존 비교 모델들 대비 유의미한 성능 개선을 확인하였다. 특히

최대 낙폭(MDD)은 -9.2%로, TradingAgents[4]의 -18.5% 대비 리스크를 절반 수준으로 방어하는 데 성공하였다. 이는 하이퍼그래프를 통해 시장의 구조적 리스크를 사전에 인지하고 대응한 결과로 해석된다.

〈표 2〉의 연산 효율성 비교에서는 제안 모델의 위치가 명확히 드러난다. 강화학습 기반인 TradeMaster[3]의 경우 평균 2ms의 매우 빠른 속도를 보이나 텍스트 맥락에 기반한 복잡한 인과관계 추론이 불가능하다. 반면 LLM 기반인 TradingAgents[4]는 평균 3,500ms(3.5초)의 추론 지연을 보인 반면,

(표 2) 연산 효율성 비교 (속도 및 비용)

지표 (Metric)	TradingAgents (LLM 기반)	TradeMaster (RL 기반)	Proposed (System 1 + 2)	개선율 (Improvement)
평균 추론 지연 (Latency)	3,500ms (3.5s)	~2ms (0.002s)	12ms (0.012s)	약 290배 (x291) 가속
월간 토큰 비용 (Cost)	\$4,500 (예상)	해당 없음	\$350	92% 절감
초당 처리 가능 틱 수 (TPS)	~0.3 Ticks/sec	> 500 Ticks/sec	> 80 Ticks/sec	고빈도 알고리즘 트레이딩 실무적용 가능
하드웨어 요구사항	High (TPU/A100 다수 필요)	Low (CPU/Single GPU)	Low (Single GPU 추론)	배포 용이성 확보



(그림 9) 추론 속도 및 비용 효율성 (Latency & Cost)

본 연구의 System 1은 12ms(0.012초)의 지연 시간을 기록하여 약 290배의 속도 향상을 달성하였다. 또한 System 2를 간헐적으로 호출하는 전략을 통해 월간 토큰 비용을 92% 절감하면서도, 초당 80틱 이상의 처리가 가능하여 실무적용 가능한 수준의 성능을 입증하였다.

5.3 사례 연구(Case Study): SVB 파산 사태


2023년 3월 실리콘밸리은행(SVB) 파산 사태 당시의 모델 반응을 분석한 결과는 본 시스템의 효율성을 잘 보여준다.

<표 3>을 참조하면, 기존 TradeMaster [3] 모델은 09:30 뉴스 발생 시 텍스트의 맥락을 읽지 못하고 주가 급락에 따른 기계적 손절매(Stop Loss)를 감행하여 손실을 확정지었다.

반면, 제안 모델은 하이퍼그래프 추론을 통해 "SVB 파산 → 스타트업 자금난 → 기술주(Tech) 약재"라는 파급 경로를 파악하고, 동시에 국채를 안전 자산으로 매수하는 헤지 전략을 수립하였다. 이후 14:00 예금 전액 보호 뉴스 발생 시에는 빅테크 중심의 리밸런싱을 통해 수익을 극대화하여, 일일 성과 +4.5%를 기록하며 위기를 기회로 전환하였다.

(표 3) 트레이딩 로그 비교 분석 (사례 연구)

시간 (Time)	시장 상황 (Event)	TradeMaster (RL Baseline) 반응	Proposed (Ours) 반응
09:30	뉴스: "SVB 유동성 위기, 주가 60% 폭락"	(Stop Loss) 지표: "RSI 과매도 진입" (Action) 금융 섹터 전량 매도	(Graph Search) SVB → 스타트업 자금줄 → Tech 기업 약재 (Action) 은행주 매도 + 국채(Safe Haven) 매수
10:15	시장: 공포 확산, 국채 급리 급락	(관망) 포트폴리오 손실 확대 (단순 현금 보유)	(Profit Taking) 국채 가격 상승분 실현 → Tech주 저점 매수 준비
14:00	뉴스: "연준, 예금 전액 보호 시사"	(추격 매수) 뒤늦게 은행주 재매수 시도	(Rebalancing) 빅테크 수익 실현 + 은행주 숏 커버링
일일 성과	수익률	-3.2% (손절매 비용 발생)	+4.5% (헤지 및 순환매 성공)



(그림 10) 제거 연구 지표 요약 (Ablation Study Summary)

5.4 제거 연구(Ablation Study)

시스템의 구성 요소별 기여도를 분석하기 위해 수행한 제거 연구(<표 4>) 결과, 하이퍼그래프를 제거할 경우 구조적 리스크 파악 실패로 MDD가 -14.8%로 악화되었으며, 지식 증류를 제거하고

System 2를 직접 운용할 경우 속도 저하로 인한 슬리피지 발생으로 수익률이 급감함을 확인하였다. 이는 본 연구에서 제안한 각 모듈이 필수적인 역할을 수행함을 시사한다.

6. 결론(Conclusion)

본 연구는 현대 금융 시장의 비선형적 복잡성과 초고속 대응성을 동시에 충족하기 위해, 인지과학의 이중 프로세스 이론(Dual Process Theory) [1]에 기반한 '하이퍼그래프 기반 협력적 트레이딩

및 추론 증류 시스템'을 제안하였다. 제안된 시스템은 속고적 사고를 담당하는 System 2(Teacher) 단계에서 동적 금융 하이퍼그래프를 구축하여 시장의 심층적인 인과관계를 구조화하고 LLM의 환각을 억제하는 한편, 추론 증류(Reasoning Distillation) [24]를 통해 고차원적인 사고 과정을 System 1(Student)의 경량화된 신경망으로 이식함으로써 밀리초(ms) 단위의 실시간 매매를 실현하였다. 이러한 접근은 학술적으로 뉴로-심볼릭 AI[5]와 금융 도메인의 성공적인 융합을 통해 설명 가능한 AI(XAI) 트레이딩의 새로운 접근법을 제시하였으며, 실무적으로는 TradingAgents[4]와 같은 기존 LLM 기반 에이전트의 주요 한계점인 느린 추론 속도와 높은 운용 비용을 획기적으로 개선(속도 약 290배 향상, 비용 92% 절감)하여 실제 고빈도 매매 환경에서의 실무 적용 가능성을 확인했다는 점

<표 4> 제거 연구 (Ablation Study)

실험 설정 (Configuration)	수익률 (CR)	MDD (Risk)	추론 속도 (Latency)	비고 (Note)
(A) Full Model (제안 모델)	42.5%	-9.2%	12ms	Best Performance
(B) w/o Hypergraph (그래프 제거)	31.2%	-14.8%	12ms	구조적 리스크 파악 실패
(C) w/o Distillation (증류 제거)	38.4%	-10.5%	3,200ms	System 2 직접 운용 (속도 저하)
(D) w/o Debate (단일 에이전트)	25.1%	-19.2%	10ms	편향(Bias) 및 환각 증가

에서 중요한 의의를 갖는다.

6.1 한계점 및 향후 연구 과제

본 연구의 한계를 극복하기 위한 향후 과제는 다음 세 가지로 요약된다.

첫째, 현재의 고정된 스키마를 넘어, Generative Agents[11]의 연구에 기반하여 새로운 개념과 관계를 스스로 발굴하는 '**자율 진화형 생성형 온톨로지(Self-Evolving Ontology)**'로 확장할 것이다.

둘째, System 1의 부족한 해석 가능성을 보완하기 위해, '**의식적 사전 확률(Consciousness Prior)**'[16] 개념을 적용하여 추론 근거를 역추적할 수 있는 XAI 모듈을 도입할 계획이다.

셋째, 기존 고빈도 매매 모델[7]의 한계를 넘어선 나노초(ns) 단위의 극초고빈도 매매(Ultra-HFT) 진입을 위해, FPGA 하드웨어 구현 및 **메타러닝(Meta-Learning)**을 통한 알고리즘 고도화를 수행할 것이다.

Acknowledgment

본 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역저능화혁신인재양성사업임(IITP-2026-RS-2020-II201462)

참고문헌

- [1] Kahneman, D. (2011). Thinking, Fast and Slow. New York: Farrar, Straus and Giroux.
- [2] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the Knowledge in a Neural Network. arXiv preprint arXiv:1503.02531.
- [3] Chu, S., Wang, H., & Chang, Y. (2023). TradeMaster: A Holistic Quantitative Trading Platform Based on Reinforcement Learning. Proceedings of the 37th Conference on Neural Information Processing Systems (NeurIPS 2023), 36, 12891-12905.
- [4] Xiao, Y., Sun, E., Luo, D., & Wang, W. (2024). TradingAgents: Multi-Agents LLM Financial Trading Framework. arXiv preprint arXiv:2412.20138.
- [5] Garcez, A. D., & Lamb, L. C. (2023). Neuro-symbolic AI: The 3rd Wave. Artificial Intelligence Review, 56(11), 12387-12406.
- [6] Liu, X. Y., Yang, H., Chen, Q., et al. (2020). FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance. NeurIPS 2020 Workshop on Deep Reinforcement Learning.
- [7] Avellaneda, M., & Stoikov, S. (2008). High-frequency trading in a limit order book. Quantitative Finance, 8(3), 217-224.
- [8] Wu, S., Irsoy, O., Lu, S., et al. (2023). BloombergGPT: A Large Language Model for Finance. arXiv preprint arXiv:2303.17564.
- [9] Yang, H., Liu, X. Y., & Wang, C. D. (2023). FinGPT: Open-Source Financial Large Language Models. arXiv preprint arXiv:2306.06031.
- [10] Li, Y., Wang, S., & Ding, H. (2024). Trading-GPT: Multi-Agent System with Layered Memory. arXiv preprint arXiv:2309.03736.
- [11] Park, J. S., O'Brien, J. C., Cai, C. J., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST '23), 1-22.
- [12] Wei, J., Wang, X., Schuurmans, D., et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. Advances in Neural Information Processing Systems (NeurIPS 2022), 35, 24824-24837.
- [13] Sawhney, R., Agarwal, S., Wadhwa, A., et al. (2021). Stock Selection via Spatiotemporal Hypergraph Attention Networks. Proceedings

- of the AAAI Conference on Artificial Intelligence (AAAI 2021), 35(1), 587-595.
- [14] Kim, R., So, C. H., Jeong, M., et al. (2019). HATR: Hypergraph Attention Networks for Multimodal Sentiment Analysis. Proceedings of the 2019 IEEE International Conference on Data Mining (ICDM), 1150-1155.
- [15] Hsieh, C. Y., et al. (2023). Distilling Step-by-Step! Outperforming Larger Language Models with Less Training Data and Smaller Model Sizes. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), 8003-8017.
- [16] Bengio, Y. (2017). The Consciousness Prior. arXiv preprint arXiv:1709.08568.
- [17] Feng, Y., You, H., Zhang, Z., Ji, R., & Gao, Y. (2019). Hypergraph Neural Networks. Proceedings of the AAAI Conference on Artificial Intelligence (AAAI 2019), 33(01), 3558-3565.
- [18] Gao, Y., Feng, Y., Ji, S., & Ji, R. (2020). HGNN+: General Hypergraph Neural Networks. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 45(3), 3181-3199.
- [19] Yadati, N., Nitin, M., Babu, M., et al. (2019). HyperGCN: A New Method for Training Graph Convolutional Networks on Hypergraphs. Advances in Neural Information Processing Systems (NeurIPS 2019), 32.
- [20] Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. arXiv preprint arXiv:1908.10063.
- [21] Schreiber, T. (2000). Measuring Information Transfer. Physical Review Letters, 85(2), 461-464.
- [22] Velickovic, P., Cucurull, G., Casanova, A., et al. (2018). Graph Attention Networks. Proceedings of the International Conference on Learning Representations (ICLR 2018).
- [23] Artzner, P., Delbaen, F., Eber, J. M., & Heath, D. (1999). Coherent Measures of Risk. Mathematical Finance, 9(3), 203-228.
- [24] Magister, L. C., Malladi, S., et al. (2023). Teaching Small Language Models to Reason. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), 1773-1785.
- [25] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems (NeurIPS 2017), 30.


■ 저자소개

◆ 허상훈



- 2023년~현재 충북대학교 산업인공 지능학과 박사과정
- 2023년 3월~현재 (주) 심스리얼리티 재직
- 관심분야: 강화학습, 멀티모달VLM 에이전트 AI, 온톨로지 금융IT, 암호화폐

◆ 황영배



- 2009년 KAIST 전기및전자공학 박사
- 2009년~2011년 삼성테크윈(주) 로봇 사업그룹 책임연구원
- 2011년~2019년 전자부품연구원 지능형영상처리연구센터 책임연구원
- 2019년~현재 충북대학교 지능로봇공학과 부교수
- 관심분야: 노이즈 모델링, 딥러닝, 객체 인식

부록 (Appendix)

부록 A. 금융 하이퍼그래프 스키마 예시

본 연구에서 사용된 하이퍼엣지의 데이터 구조는 JSON 포맷으로 정의되며, 원인(Drivers), 매개(Mediators), 결과(Targets)를 포함하여 인과관계를 명시적으로 표현한다. (상세 코드는 원문 참조)

부록 B. 시스템 하이퍼파라미터 및 환경

연구의 재현성을 위해 실험에 사용된 주요 하이퍼파라미터와 하드웨어 구성은 다음과 같다.

- 인프라: CPU: Intel i7-13700KF, GPU: NVIDIA GeForce RTX 4090, RAM: 32GB DDR5.
- 모델 파라미터: Teacher 모델은 GPT-4/GPT-4o를 기반으로 하며, 텍스트 임베딩 차원은 768이다. 지식 증류 시 $\text{Alpha}(\alpha)$ 는 0.6, $\text{Temperature}(T)$ 는 4.0으로 설정되었으며, Student 모델의 학습률은 $3e-4$, 배치 크기는 256이다.
- 데이터 파이프라인: 틱 데이터와 오더북 데이터는 지연 시간을 최소화하기 위해 로컬 NVMe SSD에서 인메모리로 로딩하여 처리한다.